



Instituto Superior de Engenharia

Politécnico de Coimbra

DEPARTAMENTO DE INFORMÁTICA E SISTEMAS

Visão Computacional para Análise de Falhas em Equipamentos Industriais

Projeto Final de Licenciatura em Engenharia Informática


Autor

Dinis Meireles de Sousa Falcão

Orientadores

Mateus Daniel Almeida Mendes

Nuno Filipe Jorge Lavado



INSTITUTO POLITÉCNICO
DE COIMBRA

INSTITUTO SUPERIOR
DE ENGENHARIA
DE COIMBRA

Coimbra, julho 2024

RESUMO

A manutenção preditiva tem ganho alguma importância devido à industrialização. Ao aproveitar tecnologias avançadas, como sensores e análises de dados, permite intervenções proativas, prevenindo paragens não planeadas, reduzindo custos e melhorando a segurança no local de trabalho. Desempenha um papel crucial na otimização das operações industriais, garantindo a eficiência, a fiabilidade e a longevidade dos equipamentos, o que se tornou cada vez mais vital no contexto da industrialização. Neste âmbito, a utilização do método Cross Industry Standard Process for Data Mining juntamente com a análise do *P-Value* em testes de estacionariedade de séries temporais é uma abordagem poderosa para estudar variações e tendências que podem indicar falhas iminentes no equipamento, contribuindo assim para a eficácia da manutenção preditiva em ambientes industriais. Este estudo da variação do *P-Value* associado ao teste de estacionariedade Augmented Dickey Fuller mostra evidências de que pode ser possível associar o aumento do *p-value* à existência de falhas no equipamento, sendo um método universal para todo o tipo de variáveis. Este tipo de análises pode, posteriormente, contribuir na aplicação da visão computacional, permitindo a identificação de padrões visuais e anomalias que podem ser precursores de falhas, complementando estas análises e reforçando a precisão das previsões.

Palavras-chave: Séries Temporais; Estacionariedade; Manutenção Preditiva; CRISP-DM; Análise de Vibração; Análise da Estacionariedade; *p-value*; Visão Computacional

ABSTRACT

Predictive maintenance has gained importance due to industrialization. By harnessing advanced technologies such as sensors and data analytics, it allows proactive interventions, preventing unplanned downtime, reducing costs, and improving workplace safety. It plays a crucial role in optimizing industrial operations, ensuring equipment efficiency, reliability, and longevity, which has become increasingly vital in the context of industrialization. In this context, the use of the Cross Industry Standard Process for Data Mining method along with the analysis of the *P-Value* in time series stationarity tests is a powerful approach to study variations and trends that may indicate imminent equipment failures, thus contributing to the effectiveness of predictive maintenance in industrial environments. This study of the *P-Value* variation associated with the Augmented Dickey Fuller stationarity test provides evidence that it may be possible to associate the increase in the *P-Value* with the occurrence of equipment failures, being a universal method for all types of variables. This type of analysis can subsequently contribute to the application of computer vision, allowing the identification of visual patterns and anomalies that can be precursors to failures, complementing these analyses and reinforcing the accuracy of the predictions.

Keywords: Time series; Stationarity; Predictive maintenance; CRISP-DM; Vibration Analysis; Stationarity Analysis; P-Value; Computer Vision

EPÍGRAFE

Winning isn't about finishing in first place. It isn't about beating the others. It is about overcoming yourself. Overcoming your body, your limitations, and your fears.

Winning means surpassing yourself and turning your dreams into reality.

Kilian Jornet

AGRADECIMENTOS

A realização deste Relatório Final de Projeto foi possível graças ao apoio fundamental de diversos colaboradores. Gostaria de expressar os meus sinceros agradecimentos a todas as pessoas e instituições que contribuíram de maneira significativa para a conclusão deste trabalho, culminando na etapa final da minha formação académica, a Licenciatura em Engenharia Informática.

Ao Instituto Superior de Engenharia de Coimbra e ao Centro de Investigação em Gestão de Ativos e Engenharia de Sistemas (RCM²⁺), pelos recursos disponibilizados.

Aos meus orientadores e professores Mateus Mendes e Nuno Lavado, pela orientação, paciência e confiança ao longo do desenvolvimento deste projeto.

Aos meus amigos e familiares, pelo apoio e incentivo.

A todos, muito obrigado!

ÍNDICE

Resumo	i
Abstract	ii
Epígrafe	iii
Agradecimentos	iv
Índice	1
Índice de tabelas	4
Índice de figuras	5
Lista de abreviaturas	6
Lista de siglas e acrónimos	7
Lista de símbolos	8
1 Introdução	9
1.1 Metodologia CRISP-DM	9
1.2 Contextualização da Manutenção Preditiva	9
1.3 Objetivos do Projeto	10
2 Séries Temporais	11
2.1 Definição	11
2.2 Componentes das Séries Temporais	11
2.3 Estacionariedade	12
2.3.1 Augmented Dickey Fuller	12
2.3.2 Decomposição Sazonal	12
2.4 Manipulação de Dados	13
2.4.1 Interpolação Linear	13
2.4.2 Redimensionamento	13
2.4.3 LOWESS Smoother Algorithm	14
2.4.4 Gramian Angular Fields	14

2.5	Modelação e Previsão	15
3	Convolutional Neural Network	16
3.1	Definição	16
3.2	Estrutura de uma CNN	16
3.2.1	Convolutional Layer	16
3.2.2	Pooling Layer	16
3.2.3	Activation Layer	17
3.2.4	Fully Connected Layer	17
3.3	Arquiteturas Avançadas	17
4	Estado da Arte	18
4.1	Análise de Falhas	18
4.2	Técnicas Tradicionais de Análise de Falhas	18
4.3	Técnicas envolvendo Redes Neurais Recorrentes	19
4.4	Técnicas envolvendo Redes Neurais Convolucionais	20
4.5	Outras Técnicas para Análise de Falhas	21
4.6	Comparação das Técnicas	21
5	Compreensão do Conjunto de Dados	23
5.1	Análise dos Dados de 2017	23
5.2	Análise dos Dados de 2018	24
5.3	Análise dos Dados de 2019	25
5.4	Visão Geral dos Dados	27
6	Preparação do Conjunto de Dados	28
6.1	Redimensionamento	28
6.2	Análise dos Períodos	29
6.3	Interpolação Linear	32
7	Análise Final	34
7.1	Decomposição Sazonal	34
7.2	Teste Augmented Dickey Fuller	34
7.3	Impacto dos <i>Outliers</i> no <i>P-Value</i>	37
7.3.1	Definição dos <i>Outliers</i>	39
7.3.2	Análise dos <i>Outliers</i>	39
7.3.3	Aplicação de Filtros de Ruído	42
8	Discussão	47
9	Conclusão	48
	Referências bibliográficas	49

Visão Computacional para Análise de Falhas em Equipamentos Industriais

Anexos	51
Anexo A - Proposta de Projeto	52
Anexo B - Monitoring of an Industrial Equipment Vibration through Analysis of Time Series Stationarity	56

ÍNDICE DE TABELAS

4.1	Comparação dos resultados dos modelos descritos	22
5.1	Estatísticas Gerais dos Dados de 2017	23
5.2	Estatísticas Gerais dos Dados de 2018.	24
5.3	Estatísticas Gerais dos Dados de 2019.	26
6.1	Estatísticas Gerais após Resample dos Dados de 2017.	28
6.2	Estatísticas Gerais após Resample dos Dados de 2018.	29
6.3	Estatísticas Gerais após Resample dos Dados de 2019.	29
6.4	Estatísticas Gerais do Primeiro Período.	29
6.5	Estatísticas Gerais do Segundo Período.	30
6.6	Estatísticas Gerais do Terceiro Período.	31
6.7	Contagem dos valores omissos.	32
6.8	Estatísticas Gerais do Segundo Período, após interpolação linear.	33
7.1	Resultados do Teste ADF para todo o período (2018-02-04 — 2018-10-27).	36

ÍNDICE DE FIGURAS

2.1	Comparação entre séries temporais estacionárias e não estacionárias	12
2.2	Exemplo da aplicação do GASF e GADF, respetivamente.	15
3.1	Representação do Método Maxpooling.	17
5.1	Gráfico dos Dados da Vibração de 2017.	24
5.2	Gráfico dos Dados da Vibração de 2018.	25
5.3	Gráfico dos Dados da Vibração de 2019.	26
6.1	Dados da Vibração do Primeiro Período.	30
6.2	Dados da Vibração do Segundo Período.	31
6.3	Dados da Vibração do Terceiro Período.	32
7.1	Decomposição Sazonal Diária da VCP 1.	35
7.2	Decomposição Sazonal Diária da VCP 2.	35
7.3	Decomposição Sazonal Diária da VCP 3.	36
7.4	Evolução do <i>P-Value</i> ao longo do tempo (Diariamente).	37
7.5	Evolução do <i>P-Value</i> Diariamente com Sobreposição (VCP1).	37
7.6	Evolução do <i>P-Value</i> Diariamente com Sobreposição (VCP2).	38
7.7	Evolução do <i>P-Value</i> Diariamente com Sobreposição (VCP3).	38
7.8	Identificação dos Valores Discrepantes.	39
7.9	Variação do <i>P-Value</i> em março 2018.	40
7.10	Variação do <i>P-Value</i> em maio 2018.	41
7.11	Variação <i>P-Value</i> em junho e setembro 2018.	42
7.12	Variação <i>P-Value</i> em julho 2018.	43
7.13	Variação do <i>P-Value</i> e da Média da VCP1 (1-Day Rolling).	44
7.14	Variação do <i>P-Value</i> e da Média da VCP1 (3-Day Rolling).	44
7.15	Variação do <i>P-Value</i> e da Média da VCP3 (15-Day Rolling).	44
7.16	Variação do <i>P-Value</i> e da Média da PCP2 (1-Day Rolling).	45
7.17	Variação do <i>P-Value</i> e da Média da TEuBA3 (7-Day Rolling).	46

LISTA DE ABREVIATURAS

PCP	Pressão da Bomba
PCP2	Pressão da Bomba 305
TEuBA	Temperatura do Motor
TEuBA3	Temperatura do Motor 412-306
VCP	Vibração da Bomba
VCP1	Vibração da Bomba 412-304
VCP2	Vibração da Bomba 412-305
VCP3	Vibração da Bomba 412-306

LISTA DE SIGLAS E ACRÓNIMOS

ADF	Augmented Dickey–Fuller
ARIMA	Autoregressive Integrated Moving Average
CRISP-DM	Cross Industry Standard Process for Data Mining
CWRU	Case Western Reserve University
DT	Decision Trees
GAF	Gramian Angular Field
GADF	Gramian Angular Difference Field
GASF	Gramian Angular Summation Field
GBM	Gradient Boosting Machines
GRU	Gated Recurrent Unit
ISEC	Instituto Superior de Engenharia de Coimbra
K-NN	K-Nearest Neighbors
LGBM	Light Gradient Boosting Machine
LOWESS	Locally Weighted Scatterplot Smoothing
LSTM	Long Short-Term Memory
MAE	Mean Absolute Error
MAPE	Mean Absolute Percentage Error
PSO	Particle Swarm Optimization
ReLU	Rectified Linear Unit
RF	Random Forests
SARIMA	Seasonal Autoregressive Integrated Moving Average
SMOTE	Synthetic Minority Over-sampling Technique
SVC	Support Vector Classification
SVM	Support Vector Machine
SVR	Support Vector Regression
TANH	Hyperbolic Tangent
XGB	Extreme Gradient Boosting

LISTA DE SÍMBOLOS

kPa Kilopascal

mm Milímetro

s Segundo

°C Grau Celsius

1 INTRODUÇÃO

As paragens não planeadas de máquinas industriais representam um dos maiores desafios operacionais para as empresas. Essas interrupções inesperadas podem causar sérios prejuízos financeiros, interrompendo a produção, atrasando entregas e aumentando os custos de reparação e manutenção. As causas dessas paragens podem variar, incluindo falhas mecânicas, problemas elétricos, desgaste de componentes e erros humanos. Independentemente da causa, a capacidade de prever e prevenir essas paragens é crucial para a operação contínua e eficiente das empresas. É nesse contexto que este projeto surge, apresentando um estudo de uma abordagem promissora.

1.1 Metodologia CRISP-DM

O **Cross Industry Standard Process for Data Mining** (CRISP-DM) é um processo cíclico que fornece uma abordagem estruturada para planejar, organizar e implementar projetos de *data mining*. Este processo consiste em seis fases principais:

- **Compreensão do problema;**
- **Compreensão dos dados;**
- **Preparação dos dados;**
- **Modelação;**
- **Avaliação dos resultados;**
- **Implantação.**

Esta metodologia fornece uma estrutura robusta e flexível que orienta os cientistas e os analistas de dados nos seus projetos, garantindo que todos os aspectos críticos são abordados. Integrar o CRISP-DM aumenta a eficiência e a eficácia dos projetos, sendo bastante útil tanto para iniciantes quanto para profissionais experientes [1].

1.2 Contextualização da Manutenção Preditiva

Nos últimos anos, a **manutenção preditiva** tem ganho destaque em diversas indústrias devido à sua capacidade de melhorar a eficiência operacional, reduzir custos e aumentar a vida útil dos ativos. Diferente das abordagens tradicionais de manutenção, como a **manutenção reativa ou corretiva**, que responde a falhas após sua ocorrência, ou a **manutenção preventiva**, que realiza intervenções em intervalos regulares independente-

mente da condição real do equipamento, a manutenção preditiva permite uma gestão mais proativa e baseada em dados [2].

A aplicação da manutenção preditiva oferece inúmeros benefícios para as organizações. Entre eles, destaca-se a capacidade de evitar paragens inesperadas, que podem resultar em perdas significativas de produtividade e custos elevados de reparação. Além disso, ao identificar e corrigir problemas, a manutenção preditiva contribui para a redução do desgaste dos equipamentos, prolongando a sua vida útil.

1.3 Objetivos do Projeto

Este projeto concentrou-se no estudo do impacto do comportamento do P-Value associado a testes de estacionariedade e desenvolvimento de um artigo científico, submetido numa revista internacional, além do estudo da visão computacional no contexto da previsão de falhas, como fase preliminar para a aplicação de um modelo CNN na deteção de falhas em tempo quase real. Este trabalho surge na sequência e continuação de um trabalho realizado anteriormente, onde foi feita uma primeira análise exploratória deste estudo, que foi aprofundada e concluída neste projeto.

Na implementação deste projeto foi utilizada a linguagem de programação *Python*, assim como o ambiente científico gratuito e de código aberto *Spyder* ¹. Também foram utilizadas as bibliotecas: *pandas*, *NumPy*, *statsmodels*, *Matplotlib*, *pickle* e *seaborn*.

Nos próximos capítulos vão ser abordados alguns temas dentro do contexto em que se insere o projeto desenvolvido, de maneira a facilitar a sua compreensão, além de uma pequena apresentação do desenvolvimento atual na área em que se insere. É ainda apresentada uma breve análise do conjunto de dados utilizado, assim como os passos e métodos de manipulação aplicados ao mesmo, que permitiram tirar as conclusões finais através da análise dos resultados.

¹<https://www.spyder-ide.org/>

2 SÉRIES TEMPORAIS

Este capítulo explora as características essenciais das séries temporais, começando pela definição. Aborda-se a decomposição das mesmas, fundamental para análises dinâmicas. Também são discutidos conceitos como estacionariedade e métodos de manipulação de dados, incluindo interpolação, redimensionamento e o algoritmo LOWESS Smoother. Por fim, é introduzida uma técnica de representação matricial e discute-se a modelação e previsão de séries temporais com diferentes técnicas.

2.1 Definição

As **séries temporais** são sequências de dados que são observadas e registadas em intervalos de tempo sucessivos, ou seja, são conjuntos de dados onde a variável tempo (independente) guia outra variável (dependente).

Estes dados podem ser analisados para identificar tendências, observar certos padrões, entre outras características dinâmicas que ocorrem no tempo. Consequentemente, esta análise permite fazer a previsão de dados futuros, podendo assim, dentro do contexto do projeto realizado, ajudar a determinar o momento em que poderão ocorrer falhas em equipamentos dos quais tenhamos acesso aos dados.

2.2 Componentes das Séries Temporais

Além da **dependência temporal**, que é uma característica fundamental que distingue as séries temporais de outros dados independentes, estas podem decompôr-se em **quatro componentes estruturais** diferentes:

- **Tendência:** tendência dos dados para aumentar ou diminuir em períodos;
- **Ciclo:** variação nos dados observada com algum padrão em longos períodos de tempo, que nem sempre são iguais;
- **Sazonalidade:** repetição de variação de dados de acordo com um certo padrão, dentro de curtos intervalos de tempo;
- **Ruído:** variações aleatórias.

Os elementos anteriores ajudam a entender os dados, permitindo análises mais detalhadas em relação às séries temporais.



Figura 2.1: Comparação entre séries temporais estacionárias e não estacionárias¹.

2.3 Estacionariedade

Uma das características necessárias para o desenvolvimento de alguns modelos e que facilita a projeção dos dados das séries temporais é a **estacionariedade**.

Uma série temporal designa-se por estacionária quando as estatísticas da mesma não sofrem variações com o tempo, não sendo dependentes dele. Ou seja, quando a média, a variância e a covariância permanecem iguais ao longo do tempo.

Através da análise de imagens, conseguimos perceber se uma série temporal apresenta esta característica ou não, como podemos verificar na Figura 2.1. No entanto, existem outros mecanismos que nos permitem verificar isso mesmo.

2.3.1 Augmented Dickey Fuller

As imagens ajudam-nos a ter uma noção da estacionariedade de uma série temporal, mas, para demonstração e determinação automática, existe um teste estatístico designado por **Augmented Dickey-Fuller (ADF)**.

O teste ADF verifica a presença de uma raiz unitária numa série temporal, o que implica que a série seja não estacionária. As hipóteses nula e alternativas associadas ao mesmo são:

- **Hipótese Nula (H_0):** A série temporal tem uma raiz unitária (não estacionária);
- **Hipótese alternativa (H_1):** A série temporal não tem uma raiz unitária (estacionária).

Tendo isto em conta, a interpretação dos resultados obtidos através deste teste é feita da seguinte forma: se o *P-Value* do teste ADF for menor do que o nível de significância escolhido, rejeitamos a hipótese nula e a série é considerada estacionária; caso contrário, rejeitamos a hipótese alternativa e concluímos que a série é não estacionária.

2.3.2 Decomposição Sazonal

Outra técnica utilizada para a análise da estacionariedade de séries temporais, e que permite uma melhor compreensão das características das mesmas, é a **decomposição**

sazonal. Esta técnica estatística consiste em separar a tendência, a sazonalidade e o ruído de um determinado conjunto de dados de série temporal.

A decomposição sazonal oferece duas abordagens diferentes: **aditiva** e **multiplicativa**. Como os próprios nomes indicam, a diferença entre estas abordagens é a operação matemática que cada uma envolve. A primeira assume que os componentes são somados para formar a série temporal original, enquanto que a segunda assume que os componentes são multiplicados:

- **Aditiva:** $y_t = S_t + T_t + E_t$
- **Multiplicativa:** $y_t = S_t * T_t * E_t$

onde T_t corresponde à tendência, S_t à sazonalidade e E_t ao ruído.

2.4 Manipulação de Dados

Para que os dados estejam na melhor forma possível para que possam ser analisados posteriormente, estes podem passar por várias técnicas de manipulação. As principais tarefas na manipulação de séries temporais incluem **limpeza**, **transformação**, **agregação** e **preenchimento de lacunas nos dados**.

2.4.1 Interpolação Linear

Uma das técnicas de preenchimento de lacunas em conjuntos de dados mais utilizadas no contexto das séries temporais é a **interpolação linear**, que é uma técnica matemática fundamental usada para estimar valores intermédios entre dois pontos conhecidos.

A interpolação linear aplica a seguinte fórmula:

$$y = y_1 + (x - x_1) * ((y_2 - y_1) / (x_2 - x_1))$$

onde (x_1, y_1) e (x_2, y_2) são dois pontos distintos conhecidos, e y é o valor calculado na posição x , sendo $x_1 < x < x_2$ [3].

Esta técnica caracteriza-se pela facilidade de implementação e capacidade de estimar valores intermédios com precisão, ou seja, sem apresentar irregularidades.

2.4.2 Redimensionamento

Outro método que é bastante utilizado neste contexto é o **resampling**. Este método consiste na alteração da frequência ou da taxa de amostragem dos dados, sendo que pode ser utilizado tanto para reduzir a frequência (**downsampling**) quanto para aumentar a

frequência (*upsampling*), ou seja, alterar a quantidade de informações que podem são capturadas.

- **Downsampling**: conversão de dados de uma frequência mais alta para uma frequência mais baixa (dados diários para dados semanais, por exemplo);
- **Upsampling**: conversão de uma frequência mais baixa para uma frequência mais alta (dados semanais para dados diários, por exemplo).

2.4.3 LOWESS Smoother Algorithm

O **Locally Weighted Scatterplot Smoothing** (LOWESS) é um algoritmo que permite modelar e suavizar dados bidimensionais, como séries temporais. Esta suavização é controlada principalmente, de entre vários parâmetros, pelo parâmetro *frac*, que representa a fração dos pontos de dados usados em cada estimativa, entre 0 e 1. Um valor menor de *frac* implica uma janela de suavização mais estreita e mais pontos de dados, resultando numa suavização mais intensa e capaz de capturar variações menores nos dados. Por outro lado, um valor maior resulta numa suavização mais suave e global, capturando tendências mais amplas nos dados.

Apesar de esta abordagem ser computacionalmente exigente, este método é importante para aqueles que procuram estudar a presença de outliers nos dados [4], ou seja, causadores de anomalias.

2.4.4 Gramian Angular Fields

O **Gramian Angular Field** (GAF) é uma técnica utilizada para converter séries temporais em imagens de duas dimensões, o que permite a aplicação de métodos de visão computacional para a análise das mesmas. Para a implementação da mesma, podem ser utilizados dois métodos diferentes: **Gramian Angular Summation Field** (GASF) e **Gramian Angular Difference Field** (GADF), considerando a soma e diferença entre cada par de dois pontos, representados na Figura 2.2, respetivamente.

Apesar de obterem resultados semelhantes [5], o primeiro é mais comum.

É capaz de transformar a série temporal numa matriz, onde cada elemento representa a relação angular entre diferentes pontos da série temporal. Por exemplo, se a série temporal possui n observações, a matriz resultante terá dimensões $n * n$. Este método permite mostrar diferenças entre os dados, facilitando assim a identificação de padrões e características que podem não ser evidentes na representação original dos dados [6].

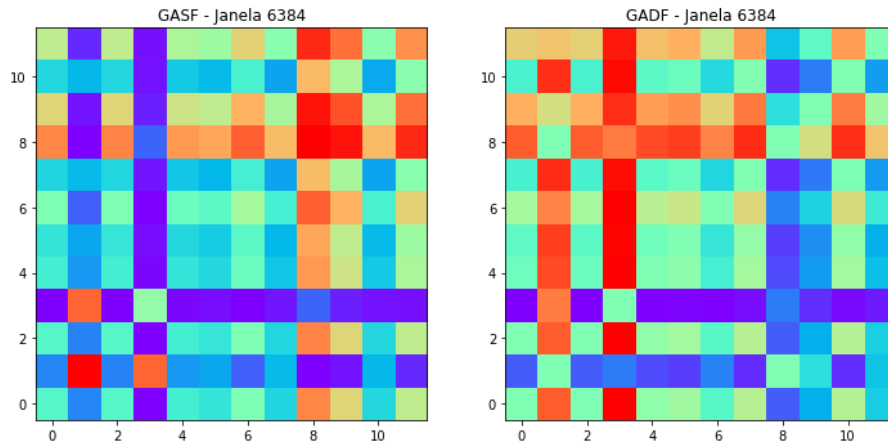


Figura 2.2: Exemplo da aplicação do GASF e GADF, respectivamente.

2.5 Modelação e Previsão

A modelação e previsão de séries temporais são componentes essenciais para utilizar dados históricos a fim de prever valores futuros. Existem diferentes abordagens que permitem modelar este tipo de dados:

- Modelos **Autoregressive Integrated Moving Average** (ARIMA);
- Modelos **Seasonal Autoregressive Integrated Moving Average** (SARIMA);
- Redes Neurais Recorrentes, como **Long Short-Term Memory** (LSTM) e **Gated Recurrent Unit** (GRU);
- **Convolutional Neural Networks** (CNN).

Estes modelos, em conjunto com algumas técnicas de avaliação, como divisão em conjuntos de treino, validação e teste, métricas de erro, como **Mean Absolute Error** (MAE) e o **Mean Absolute Percentage Error** (MAPE), entre outras, permitem alguma precisão e confiabilidade na previsão de séries temporais.

¹Fonte: <https://medium.com/@gisely.alves/s%C3%A9ries-temporais-parte-1-20fca5a6c7cd>

3 CONVOLUTIONAL NEURAL NETWORK

Este capítulo aborda as CNN, começando com uma definição e descrição, seguida pela estrutura detalhada das mesmas. Também são exploradas algumas arquiteturas avançadas que demonstram as variações e melhorias para diferentes aplicações e estudos.

3.1 Definição

As **Convolutional Neural Networks** são uma classe de redes neuronais artificiais utilizadas em *deep learning* que aprendem diretamente a partir dos dados.

Oriundas do estudo da visão no córtex cerebral, são particularmente úteis para encontrar padrões em imagens, permitindo reconhecer objetos, classes e categorias. Também podem ser bastante eficazes para classificar dados de áudio, séries temporais e sinais.

3.2 Estrutura de uma CNN

As redes neuronais convolucionais são compostas por uma camada de entrada, uma camada de saída e várias camadas ocultas entre elas. Estas camadas realizam operações que alteram os dados com a intenção de aprender características específicas dos mesmos, sendo as mais comuns: **convolutional layer**, **pooling layer**, **activation layer** e **fully connected layer**.

3.2.1 Convolutional Layer

Esta corresponde à primeira camada de uma CNN. Aplica convoluções aos dados de entrada utilizando filtros (ou kernels), que percorrem a imagem de entrada, detetando características da mesma, como bordas, texturas e padrões. Estas operações são essenciais para preservar a relação espacial entre os pixels da imagem.

3.2.2 Pooling Layer

Tem como objetivo reduzir a dimensão da imagem de entrada e dos mapas de características subsequentes (ou *features maps*). Isto reduz a carga computacional, o uso de memória e o número de parâmetros, diminuindo assim o risco de *overfitting*.

O método de simplificação mais utilizado é o *maxpooling*, no qual apenas o maior número da unidade é passado para a saída, como demonstrado na Figura 3.1. No entanto,




Figura 3.1: Representação do Método Maxpooling¹.

são ainda conhecidos outros métodos, como *average pooling*, que calcula média entre os valores e *min pooling*, que seleciona o menor valor da unidade.

3.2.3 Activation Layer

Após a *convolutional layer*, uma função de ativação é aplicada para introduzir não-linearidades no modelo, permitindo que este aprenda a representar funções mais complexas. Existem várias funções de ativação, como **sigmoid**, **Hyperbolic tangent** (tanh) e **softmax**, mas a mais indicada para utilizar em CNN's é a **Rectified Linear Unit** (ReLU), por ser mais eficiente computacionalmente.

A **ReLU** ativa apenas as unidades onde o valor é positivo, ajudando a evitar o problema do desvanecimento do gradiente, que torna difícil a captura de dependências de longo prazo.

3.2.4 Fully Connected Layer

Esta camada corresponde à camada final de uma CNN, que recebe a saída da camada anterior e a conecta a um número de neurónios, correspondente à quantidade de classes. Esta é responsável por consolidar as características extraídas nas camadas anteriores e fornecer a previsão final do modelo.

3.3 Arquiteturas Avançadas

Existem várias arquiteturas avançadas de CNN's que foram desenvolvidas para melhorar a eficiência e a precisão em tarefas específicas. Algumas destas arquiteturas podem ser **LeNet**, **AlexNet**, **VGG16**, **ResNet-50**, e **Inception-V1**, cada uma com suas particularidades e performances em diferentes estudos [7].

¹Fonte: https://nico-curti.github.io/NumPyNet/NumPyNet/layers/maxpool_layer.html

4 ESTADO DA ARTE

4.1 Análise de Falhas

A análise de falhas em equipamentos industriais é uma área crucial para garantir a eficiência, segurança e confiança nas operações industriais.

Tradicionalmente, diversas técnicas de inspeção visual humana e métodos de monitorização baseados em sensores têm sido as principais ferramentas para detetar e diagnosticar essas falhas em equipamentos. No entanto, métodos como esses podem ser limitados, especialmente em ambientes industriais de elevada complexidade e com grandes volumes de dados.

A visão computacional emergiu como uma abordagem promissora para análise de falhas em equipamentos industriais, oferecendo a capacidade de automatizar e aprimorar significativamente o processo de deteção e diagnóstico de falhas. Através da captura, processamento e interpretação de imagens, a visão computacional consegue identificar padrões associados a falhas e/ou anomalias.

4.2 Técnicas Tradicionais de Análise de Falhas

Como já foi dito anteriormente, existe uma variedade de abordagens, cada uma com suas vantagens e desvantagens. No entanto, é fundamental seguir as melhores práticas de preparação de dados, treino do modelo e validação para garantir a precisão e confiabilidade das previsões.

Algumas abordagens são eficazes na modelação de relações lineares e estacionárias em séries temporais, como **Autoregressive Integrated Moving Average** (ARIMA) ou **Seasonal Autoregressive Integrated Moving Average** (SARIMA), embora estes modelos sejam normalmente mais eficientes em previsões de janelas de dados mais curtas e com alguma linearidade [8].

Também é comum usar abordagens de **Ensemble Learning**, que combinam vários modelos, como **Random Forests** (RF) e **Gradient Boosting Machines** (GBM). No entanto, cada modelo deve ser desenvolvido de acordo com necessidades e características específicas do problema que pretendem solucionar.

4.3 Técnicas envolvendo Redes Neurais Recorrentes

Outras abordagens destacam-se pela capacidade de capturar dependências temporais em dados sequencias, que é essencial para prever falhas de equipamentos ao longo do tempo. Essas abordagens incluem redes neurais recorrentes, nas quais estão inseridas LSTM e GRU.

De maneira a comparar o comportamento destas duas abordagens referidas anteriormente no contexto da manutenção industrial, Mateus et al. [9] desenvolveram vários modelos com diferentes arquiteturas e hiperparâmetros para prever os valores de seis sensores associados a uma prensa de papel industrial, com uma antecendência de 30 dias. Os resultados obtidos, através das métricas MAPE e MAE, com estas experiências revelaram uma maior eficiência e simplicidade dos modelos que utilizaram GRU (5.38% MAPE e 0.85 MAE), apesar de, tanto o modelo que envolveu LSTM (6.48% MAPE e 1.10 MAE), quanto o modelo com GRU, terem obtido bons resultados.

Estes modelos também podem ser combinados entre si, aproveitando aquilo que cada um melhor tem para oferecer. E foi com este pensamento que, Anupam Kumar et al. [10], foi capaz de desenvolver um modelo **Hybrid LSTM-GRU**. Através do desenvolvimento deste modelo, após a comparação com seis modelos diferentes de *deep learning* com os mesmos hiper-parâmetros, foi provada a superioridade da combinação destas duas técnicas, que obtiveram excelentes resultados (97.9% *accuracy*) nas métricas de avaliação utilizadas: *accuracy*, *kappa* e *F1-score*.

No entanto, nem sempre a arquitetura final do modelo que está a ser utilizada é o aspeto mais importante e que causa maior impacto no sucesso destas previsões. Tendo em conta que, muitas vezes, o conjunto de dados utilizados nestas experiências não se encontra no melhor estado para ser estudado, existem várias técnicas de pré-processamento dos dados que permitem manipular os mesmos da melhor maneira. Assim sendo, Balduíno César Mateus et al. [11] testou um modelo GRU com três cenários de pré-processamento diferentes, que foram: eliminação de dados com valores discrepantes, suavização dos dados através da aplicação do filtro LOWESS e a combinação dos dois cenários anteriores. Apesar da aplicação dos cenários 1 e 2 mostrar uma melhoria significativa nas métricas utilizadas para avaliar os modelos, o cenário que combina estas duas técnicas foi, sem dúvida, aquele que obteve melhores resultados (1.20% MAPE e 0.30 MAE). Além de ter sido provado a eficiência dos modelos GRU, mostra que o pré-processamento de dados pode desempenhar um papel muito importante na melhoria das previsões.

4.4 Técnicas envolvendo Redes Neurais Convolucionais

Ainda neste contexto, pela capacidade de capturar características espaciais em dados de imagem, que é essencial para tarefas de reconhecimento de padrões e detecção de anomalias, destacam-se algumas abordagens, que incluem redes neurais convolucionais, nomeadamente CNN's.

Com o objetivo de fornecer um conjunto de dados completo para o estudo e desenvolvimento de técnicas de machine learning, a **Case Western Reserve University** (CWRU) apresenta um conjunto de dados [12] com diferentes tipos de dados de rolamentos: *normal bearings, single-point drive end e fan end defects*.

Através da utilização deste conjunto de dados, Dhiraj Neupane et al. [13] e Sinchana N Raj et al. [14] pretenderam mostrar o desempenho de modelos com CNN em tarefas de classificação de falhas, tendo obtido excelentes resultados. Em relação à primeira referência, foi desenvolvido um modelo envolvendo uma CNN de apenas uma dimensão, que foi comparado com diversos outros, com diferentes arquiteturas. Um dos modelos em comparação foi um modelo que envolveu uma CNN de duas dimensões que, devido ao número de dimensões, necessitou de um pré-processamento diferente dos dados: conversão para imagens 40×40 . Este estudo obteve melhores resultados para a primeira arquitetura apresentada (99.34% - 99.49% *accuracy*), o que pode ser explicado pelas diferenças pré-processamento ou nas dimensões. Ao contrário deste, a segunda referência apresenta um modelo envolvendo uma CNN de duas dimensões que, apesar de ter obtido resultados ligeiramente inferiores à arquitetura anterior (94.00% *accuracy*), continuam a ser uma prova da eficácia deste tipo de implementações. Além disto, também foram aplicadas diversas técnicas de visualização e manipulação de dados ao longo do desenvolvimento do mesmo, que permitiram perceber um pouco melhor as características dos dados.

Tal como já foi dito anteriormente, a possibilidade de combinar modelos com diferentes arquiteturas revela ser uma abordagem bastante promissora neste contexto. Posto isto, Yufeng Qin e Xianjun Shi [15], com o conjunto de dados anterior e com recurso a uma *fusion layer*, desenvolveram um modelo com dois canais de entrada que envolveram: uma CNN de uma dimensão e uma CNN de duas dimensões. Os resultados obtidos neste estudo foram quase perfeitos (99.50% *accuracy* e 1.00 *F1-score*), portanto decidiram desequilibrar o conjunto de dados. Após esta mudança, os resultados foram ligeiramente inferiores (96.80% *accuracy* e 0.97 *F1-score*), mas esta experiência continuou a contribuir positivamente para o estudo do sucesso das redes neurais convolucionais.

Tendo em conta as investigações e projetos anteriores, podemos concluir que a aplicação de modelos envolvendo CNN para análise de falhas em equipamentos industriais é, efetivamente, uma excelente ferramenta. Além disso, após uma breve análise de cada modelo desenvolvido, depreendemos que o sucesso de uma solução destas, neste tipo

de problemas, depende principalmente do pré-processamento dos dados, da organização do conjunto de dados utilizado e da arquitetura final do modelo.

4.5 Outras Técnicas para Análise de Falhas

Além das diferentes técnicas referidas anteriormente, ainda existem muitas outras técnicas de *machine learning* que, apesar de já não serem tão utilizadas, é importante fazer referência às mesmas pela sua utilização em tarefas de classificação e regressão. Algumas dessas técnicas podem envolver: **Light Gradient Boosting Machine** (LGBM), **Random Forest** (RF) e **Decision Trees** (DT), **Extreme Gradient Boosting** (XGb), **Support Vector Machine** (SVM), **k-Nearest Neighbors** (k-NN), entre outras. Debshree Bhattacharya e Manoj Kumar Nigam [16], com o objetivo de encontrar, de forma eficiente, rápida e segura, falhas em sistemas de rede elétrica e de estudar a eficiência de algumas das técnicas anteriores, desenvolveram quatro modelos de classificação diferentes. Com recurso a uma *framework* designada por **Optuna**, otimizaram os hiper-parâmetros dos diferentes modelos e concluíram alguma superioridade do modelo envolvendo LGBM (99.54% *accuracy*) em relação aos restantes. Para detetar e classificar diferentes tipos de falhas em linhas de transmissão, Al Kharusi et al. [17] também desenvolveram alguns modelos com algumas das abordagens referidas anteriormente. Ainda aplicaram uma técnica de balanceamento do conjunto de dados, **Synthetic Minority Over-sampling Technique** (SMOTE) e otimizaram os hiper-parâmetros dos modelos através da **Bayesian Optimization**. Nesta experiência, o modelo desenvolvido com DT foi aquele que obteve melhores resultados (99.40% *accuracy*) e o modelo com k-NN foi o que esteve pior (90.60% *accuracy*), para o mesmo conjunto de dados.

Também, como nas técnicas anteriores, foi explorado pelos investigadores Papia Ray e Deban Prasad Mishra [18], a combinação de modelos, **Hybrid SVM. Support Vector Classification** (SVC) é usado para a classificação de falhas e **Support Vector Regression** (SVR) para a deteção das mesmas. Com recurso à biblioteca **LIBSVM** e ao **Particle Swarm Optimization** (PSO), os hiper-parâmetros foram explorados e otimizados. Este estudo comparou o modelo desenvolvido com alguns modelos que envolveram outras técnicas, destacando-se (99.20% *accuracy*).

4.6 Comparação das Técnicas

Ao longo deste capítulo foram descritas diversas técnicas que, no contexto deste projeto, são consideradas essenciais na ajuda de classificação e deteção de falhas. Podemos ver uma pequena comparação dos resultados obtidos, através de métricas de erro e avaliação, dos modelos desenvolvidos por diferentes investigadores na Tabela 4.1. Através da análise da mesma, conseguimos perceber que todos os modelos obtiveram

excelentes resultados ($>90.60\%$ *accuracy*, <1.10 MAE e $<6.48\%$ MAPE). No entanto, destacam-se os modelos: TC - CNN e LGBM.

Tabela 4.1: Comparação dos resultados dos modelos descritos

Modelo	<i>accuracy</i>	MAE	MAPE	<i>F1-score</i>
LSTM [9]	-	1.10	6.48%	-
GRU [9] [11]	-	0.30 - 0.85	1.20% - 5.38%	-
Hybrid LSTM-GRU [10]	97.90%	-	-	-
1D - CNN [13]	99.34% - 99.49%	-	-	-
2D - CNN [14]	94.00%	-	-	-
TC - CNN [15]	96.80% - 99.50%	-	-	0.97 - 1.00
LGBM [16]	99.54%	-	-	-
DT [16]	99.40%	-	-	-
k-NN [16]	90.60%	-	-	-
Hybrid SVM [18]	99.20%	-	-	-

5 COMPREENSÃO DO CONJUNTO DE DADOS

O conjunto de dados utilizado neste projeto contém informações de três bombas de aparas industriais, recolhidas por um conjunto de sensores ao longo dos anos de 2017, 2018 e 2019. Os dados foram registados com uma frequência de um minuto entre cada leitura, resultando num total de 525 600 linhas por ano.

Embora o conjunto completo incluía 31 variáveis, este projeto foca-se especificamente em três delas, pela sensibilidade em certos problemas mecânicos: **Vibração da Bomba 412-304 (VCP1)**, **Vibração da Bomba 412-305 (VCP2)** e **Vibração da Bomba 412-306 (VCP3)**. Todas estas variáveis são medidas em milímetros por segundo (mm/s).

5.1 Análise dos Dados de 2017

Inicialmente, foi realizada uma análise descritiva das estatísticas gerais dos dados para obter uma visão simplificada do conjunto. Os resultados dessa análise estão apresentados na Tabela 5.1.

Os dados analisados deveriam conter 525 600 registos, correspondendo ao número total de minutos num ano. No entanto, ao observar a Tabela 5.1, podemos notar que as frequências absolutas para as variáveis VCP1, VCP2 e VCP3 são inferiores a esse valor. Isto indica a presença de valores omissos nos dados, o que também pode ser verificado através da Figura 5.1. Além disto, também podemos notar alguns valores discrepantes ao longo do período temporal das três variáveis, assim como valores negativos. Isto pode ser explicado através da forma como os sinais de vibração são capturados e representados matematicamente no contexto de medição em que se encontram.

Ao analisar o valor médio das vibrações das bombas, verificamos que a VCP2 apresenta

Tabela 5.1: Estatísticas Gerais dos Dados de 2017

Estatísticas	VCP1	VCP2	VCP3
Frequência Absoluta	516 636	487 879	512 470
Média	0.6945	2.1319	1.0284
Desvio-Padrão	0.2967	0.8418	0.4588
Min	-0.0545	-0.0661	-0.0353
25%	0.5592	1.9577	0.8187
50%	0.6689	2.2460	0.9571
75%	0.8432	2.4869	1.1153
Max	5.3409	25.1097	2.5994




Figura 5.1: Gráfico dos Dados da Vibração de 2017.

Tabela 5.2: Estatísticas Gerais dos Dados de 2018.

Estatísticas	VCP1	VCP2	VCP3
Frequência Absoluta	517 573	517 683	517 379
Média	1.02538	2.0447	1.8507
Desvio-Padrão	0.5716	0.5395	0.8127
Min	-0.0485	-0.0429	-0.0130
25%	0.6854	1.8702	1.5338
50%	0.8491	2.1194	1.8123
75%	1.2006	2.3745	2.0278
Max	23.9020	19.8924	9.8808

uma média significativamente maior, com $2,1319 \text{ mm/s}$. Essa diferença nas médias sugere que as bombas podem operar em condições diferentes ou até mesmo apresentar algum desgaste.

A análise do desvio-padrão mostra que a VCP2 apresenta uma maior variabilidade e inconsistência nas suas medições de vibração, que também pode ser verificado pelo facto de o valor máximo ser bastante superior. Por outro lado, a VCP1 e a VCP3 têm desvios-padrão menores, o que sugere medições mais consistentes.

5.2 Análise dos Dados de 2018

Em relação aos dados referentes ao ano de 2018, a Tabela 5.2 apresenta as estatísticas gerais dos mesmos.




Figura 5.2: Gráfico dos Dados da Vibração de 2018.

A frequência absoluta é ligeiramente inferior ao total esperado de 525 600 registos anuais, indicando, mais uma vez, a presença de alguns valores omissos. Esta presença pode ser verificada através das falhas existentes ao longo da Figura 5.2.

Em relação à média das variáveis, podemos verificar que a variável VCP 1 é significativamente inferior às restantes, indicando mais uma vez a possibilidade de existência de condições diferentes entre as bombas.

Este ano foi verificado uma maior estabilidade e consistência dos dados, pois o desvio-padrão das diferentes variáveis encontra-se ligeiramente próximo. No entanto, ao analisar os valores máximos ainda podemos encontrar algumas oscilações entre as diferentes variáveis.

5.3 Análise dos Dados de 2019

Por último, as estatísticas gerais dos dados referentes ao ano de 2019 podem ser consultados na Tabela 5.3.

Em 2019, a frequência absoluta continua a ser menor relativamente à esperada. Isto indica que também existem valores omissos neste ano, verificado na Figura 5.3.

A média não apresenta diferenças significativas entre as diferentes variáveis, o que faz deste ano um pouco mais regular. O mesmo pode dizer-se em relação ao desvio-padrão, que também apresenta pequenas diferenças, apesar de o valor máximo da VCP3 ser bastante superior às restantes.

Tabela 5.3: Estatísticas Gerais dos Dados de 2019.

Estatísticas	VCP1	VCP2	VCP3
Frequência Absoluta	508 706	511 044	497 572
Média	1.4740	1.8879	1.5367
Desvio-Padrão	0.5362	0.6661	0.7619
Min	-0.0501	-0.0441	-0.0473
25%	1.2129	1.5473	1.0693
50%	1.5157	1.9928	1.3615
75%	1.8479	2.3408	1.7370
Max	11.5775	10.0321	20.6855




Figura 5.3: Gráfico dos Dados da Vibração de 2019.

5.4 Visão Geral dos Dados

Através da análise das Tabelas [5.1, 5.2, 5.3] e Figuras [5.1, 5.2, 5.3] correspondentes ao conjunto de dados dos 3 anos, conseguimos tirar algumas conclusões:

- Foi identificado que em todos os anos analisados, o número de registos é inferior ao total esperado de 525 600, indicando a presença de valores omissos nos dados;
- Ao longo dos três anos, a variável VCP2 apresentou uma média superior quando comparada às variáveis VCP1 e VCP3, sendo essa diferença mais acentuada em 2017;
- Em 2018 e 2019, foi verificado uma maior estabilidade e consistência nas medições entre todas as variáveis;
- No ano de 2019, as médias das três variáveis mostraram-se mais próximas entre si, indicando um comportamento mais regular das bombas;

Estas análises dos dados fornecem informações essenciais para uma melhor compreensão do comportamento das bombas que, por sua vez, podem ser utilizadas no futuro.

6 PREPARAÇÃO DO CONJUNTO DE DADOS

Nesta fase, o objetivo é otimizar os dados para que possam ser utilizados de maneira eficiente no estudo proposto por este projeto.

6.1 Redimensionamento

Considerando o elevado tamanho do conjunto de dados, foi necessário aplicar uma técnica de redimensionamento conhecida como *downsampling*, de maneira a tornar as análises mais eficientes e menos demoradas.

Esta técnica envolveu a alteração do período de amostragem original, que era de 1 minuto, para uma nova frequência de 5 minutos, com recurso ao método *resample()*¹, presente na biblioteca *pandas*. Para fazer isso, utilizámos a média dos valores agregados em cada intervalo de 5 minutos, permitindo assim reduzir o número total de linhas para um quinto do valor inicial, 105 120 em cada ano.

As Tabelas [6.1, 6.2, 6.3] mostram as estatísticas gerais do conjunto de dados dos diferentes anos após a aplicação do *downsampling*.

Após a redução do conjunto de dados, fica claro que os valores médios permaneceram em grande parte sem alterações significativas. No entanto, os valores máximos foram afetados.

Os dados foram sujeitos a uma análise mais aprofundada, sendo que alguns períodos foram identificados como candidatos para análises posteriores, dada a sua pequena percentagem de valores omissos e a sua extensão temporal:

¹<https://pandas.pydata.org/docs/reference/api/pandas.DataFrame.resample.html>

Tabela 6.1: Estatísticas Gerais após Resample dos Dados de 2017.

Estatísticas	VCP1	VCP2	VCP3
Frequência Absoluta	103 549	97 883	102 715
Média	0.6946	2.1422	1.0281
Desvio-Padrão	0.2821	0.8819	0.4522
Min	-0.0534	-0.0488	-0.0178
25%	0.5751	1.9957	0.8339
50%	0.6735	2.2473	0.9584
75%	0.8400	2.4728	1.0826
Max	4.5286	24.4110	2.5505

Tabela 6.2: Estatísticas Gerais após Resample dos Dados de 2018.

Estatísticas	VCP1	VCP2	VCP3
Frequência Absoluta	103 734	103 752	103 692
Média	1.0264	2.0447	1.8505
Desvio-Padrão	0.5641	0.5239	0.8032
Min	-0.0481	-0.0429	-0.0126
25%	0.7163	1.8927	1.5500
50%	0.8542	2.1201	1.8188
75%	1.1165	2.3634	2.0016
Max	21.2819	6.6306	5.9446

Tabela 6.3: Estatísticas Gerais após Resample dos Dados de 2019.

Estatísticas	VCP1	VCP2	VCP3
Frequência Absoluta	101 886	102 354	99 658
Média	1.4740	1.8879	1.5368
Desvio-Padrão	0.5271	0.6527	0.7386
Min	-0.0501	-0.0441	-0.0143
25%	1.2133	1.5555	1.0736
50%	1.5128	1.9967	1.3633
75%	1.8436	2.3356	1.7308
Max	5.8121	7.4538	17.2504

- 2017-11-05 — 2018-01-20;
- 2018-02-04 — 2018-10-27;
- 2018-11-04 — 2019-02-16.

6.2 Análise dos Períodos

Depois de identificados os períodos que se encontram em melhores condições para o estudo pretendido com este projeto, passou-se então à análise das estatísticas gerais de cada um destes períodos, que podemos ver nas Tabelas [6.4, 6.5, 6.6].

Tabela 6.4: Estatísticas Gerais do Primeiro Período.

Estatísticas	VCP1	VCP2	VCP3
Frequência Absoluta	22 176	22 176	22 176
Média	0.6539	1.9798	1.8262
Desvio-Padrão	0.1790	0.4269	0.3568
Min	-0.0477	-0.0429	-0.0115
25%	0.5907	1.8865	1.7999
50%	0.6565	2.0890	1.8745
75%	0.7294	2.2079	1.9587
Max	1.9653	2.6859	2.3692

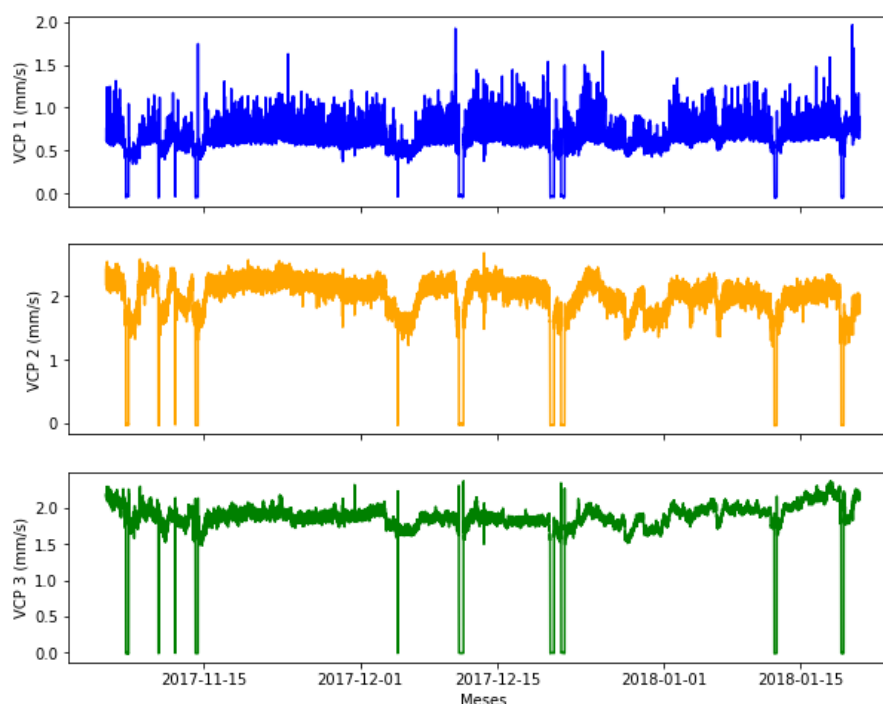


Figura 6.1: Dados da Vibração do Primeiro Período.

Tabela 6.5: Estatísticas Gerais do Segundo Período.

Estatísticas	VCP1	VCP2	VCP3
Frequência Absoluta	76 479	76 525	76 507
Média	0.8641	2.0479	1.8748
Desvio-Padrão	0.4021	0.5324	0.8873
Min	-0.0481	-0.0429	-0.0126
25%	0.7105	1.8761	1.4240
50%	0.8257	2.1164	1.8144
75%	0.9713	2.3878	2.0147
Max	21.2819	6.6306	5.9446

Ao analisar a Tabela 6.4, podemos verificar que as três variáveis têm 22 176 registos, o que indica que não há valores omissos neste período. Isto também pode ser verificado através da análise da Figura 6.1, pela inexistência de falhas ao longo das diferentes linhas.

As variáveis VCP2 e VCP3 apresentam médias superiores a VCP1, sugerindo que as bombas 412-305 e 412-306 têm níveis de vibração mais elevados.

Apesar de o valor do desvio-padrão ser inferior em VCP1, essa diferença não é significativa, indicando que é um período consistente e regular. Isso também pode ser verificado pela semelhança entre os valores máximo e mínimo das diferentes variáveis.

Passando à análise da Tabela 6.5, podemos observar a existência de valores omissos pelo facto de a frequência absoluta apresentar valores diferentes nas três variáveis.




Figura 6.2: Dados da Vibração do Segundo Período.

Tabela 6.6: Estatísticas Gerais do Terceiro Período.

Estatísticas	VCP1	VCP2	VCP3
Frequência Absoluta	30 240	30 240	30 240
Média	1.9233	2.0938	1.5593
Desvio-Padrão	0.4292	0.4846	0.3842
Min	-0.0429	-0.0405	-0.0083
25%	1.9103	2.0262	1.4847
50%	2.0160	2.1977	1.6375
75%	2.1097	2.3332	1.7737
Max	3.2700	2.9388	2.1758

Como são poucos valores omissos, estes não são perceptíveis na Figura 6.2, mas podemos analisar a variação das diferentes variáveis ao longo do tempo.

Em relação à média, VCP2 e VCP3 apresentam médias superiores a VCP 1.

O desvio-padrão é superior em VCP3, seguida por VCP2 e VCP1, mas não é uma diferença significativa. No entanto, ao analisarmos o valor máximo de cada variável, podemos verificar uma superioridade da variável VCP1 em comparação com as restantes.

Analisando a Tabela 6.6, todas as variáveis têm 30 240 registos, indicando que também não há valores omissos neste período. Mais uma vez, também podemos visualizar a Figura 6.3 para verificar isso mesmo.

Este período apresenta uma maior estabilidade nos dados, tendo em conta que os va-




Figura 6.3: Dados da Vibração do Terceiro Período.

Tabela 6.7: Contagem dos valores omissos.

Período	VCP1	VCP2	VCP3
2017-11-05 — 2018-01-20	0	0	0
2018-02-04 — 2018-10-27	129	83	101
2018-11-04 — 2019-02-16	0	0	0

lores da média das diferentes variáveis são semelhantes.

Além disto, o desvio-padrão também é bastante semelhante entre as mesmas, sugerindo uma maior consistência nas medições. O mesmo também pode ser verificado pelos valores mínimo e máximo.

6.3 Interpolação Linear

Como foi verificado com as análises anteriores, o segundo período identificado apresenta alguns valores omissos, quantificados na Tabela 6.7.

De maneira a resolver isto, foi utilizada uma técnica de preenchimento, cujo nome é Interpolação Linear. Esta técnica foi aplicada com recurso ao método *interpolate()*², presente na biblioteca *pandas*.

As estatísticas gerais do segundo período, após a aplicação de interpolação linear, podem ser consultadas na Tabela 6.8.

²<https://pandas.pydata.org/docs/reference/api/pandas.DataFrame.interpolate.html>

Tabela 6.8: Estatísticas Gerais do Segundo Período, após interpolação linear.

Estatísticas	VCP1	VCP2	VCP3
Frequência Absoluta	76 608	76 608	76 608
Média	0.8667	2.0481	1.8743
Desvio-Padrão	0.4274	0.5325	0.8873
Min	-0.0481	-0.0429	-0.0126
25%	0.7105	1.8762	1.4240
50%	0.8258	2.1170	1.8143
75%	0.9717	2.3880	2.0144
Max	21.2819	6.6306	5.9446

Comparando as Tabelas 6.5 e 6.8, podemos ver que a interpolação linear preencheu os valores omissos, resultando numa frequência absoluta igual ao número total esperado de registos para todas as variáveis.

As diferenças entre o antes e o após interpolação linear são mínimas, o que indica que esta técnica preservou a integridade dos dados enquanto preenchia os valores omissos.

7 ANÁLISE FINAL

Após a identificação dos intervalos, preparação e análise dos mesmos, foi concluído que o segundo período seria o ideal para a continuação do estudo deste projeto. Esta escolha pode ser justificada pela sua extensão temporal, que é bastante superior aos restantes períodos.

7.1 Decomposição Sazonal

Começando pela decomposição sazonal diária ($period = 24 * (60/5) = 288$) das diferentes variáveis no período selecionado, que pode ser observado nas Figuras [7.1, 7.2 e 7.3], podemos tirar algumas conclusões em relação ao comportamento das variáveis. Esta foi realizada com recurso ao método *seasonal_decompose*, presente na biblioteca *statsmodels*.

Analisando a Figura 7.1, conseguimos visualizar alguma estabilidade da tendência ao longo do tempo, verificando-se um aumento final. A sazonalidade apresenta padrões repetitivos, sendo que nestes padrões observa-se a presença de vários picos crescentes. Em relação ao Resíduo, como este apresenta o mesmo padrão da variação da variável, significa que estão associados, ou seja, o gráfico está correto.

Passando à análise da Figura 7.2, verificamos uma menor estabilidade da tendência, na qual conseguimos identificar a presença de um vale e uma diminuição final. A sazonalidade, mais uma vez, apresenta padrões repetitivos, mas com maior variação de valores. Quanto ao Resíduo, verificamos mais uma vez a repetição do padrão da variação variável.

Por último, a Figura 7.3 apresenta uma queda inicial na tendência, mas uma grande estabilidade a partir desse momento. Em relação à Sazonalidade, voltamos a verificar padrões repetitivos com grande variação de valores. O Resíduo volta a ter o mesmo padrão da variável.

7.2 Teste Augmented Dickey Fuller

Tendo em conta o objetivo deste projeto, e de maneira a verificar a estacionariedade da série temporal identificada, foi realizado um teste estatístico cujo nome é *Augmented Dickey Fuller*.




Figura 7.1: Decomposição Sazonal Diária da VCP 1.




Figura 7.2: Decomposição Sazonal Diária da VCP 2.




Figura 7.3: Decomposição Sazonal Diária da VCP 3.

	VCP 1	VCP 2	VCP 3
Teste ADF	-18.90	-11.43	-6.16
<i>p-value</i>	0.0	6.53×10^{-21}	7.18×10^{-08}

Tabela 7.1: Resultados do Teste ADF para todo o período (2018-02-04 — 2018-10-27).

Após a aplicação do método *adfuller*, presente na biblioteca *statsmodels*, obtivemos os resultados que podemos observar na Tabela 7.1, para as diferentes variáveis em estudo. Posto isto, através da análise da Tabela 7.1, observamos que todos os valores do teste estatístico ADF são fortemente negativos, indicando uma forte evidência contra a hipótese nula de não estacionaridade no período (2018-02-04 — 2018-10-27) como um todo. Assim, podemos concluir que a série temporal identificada é estacionária para o conjunto de variáveis em análise, o que vai ao encontro do que podemos observar nas Figuras [6.2, 7.1, 7.2 e 7.3].

De seguida, observou-se a evolução diária do *P-Value* ao longo da série temporal, que está ilustrada na Figura 7.4.

Através da análise da Figura 7.4, verificamos diversos picos do *P-Value* que ultrapassam os 0.05, o que indica que a série temporal não é estacionária. No entanto, quando a análise é realizada numa janela menor (Diária, neste caso), a estacionariedade pode não ser garantida, mas não significa que a série temporal não seja estacionária, na sua totalidade.

Foi ainda ilustrada nas Figuras [7.5, 7.6 e 7.7] a variação do *P-Value* e das diferentes variáveis com sobreposição, de maneira a perceber de melhor forma o comportamento do *P-Value* em relação às mudanças nas variáveis. Ao analisar esses gráficos, reparamos que o *P-Value* varia bastante ao longo do período temporal, apresentando diversos picos, tal como as variáveis em estudo. No entanto, estes gráficos ainda não permitem a

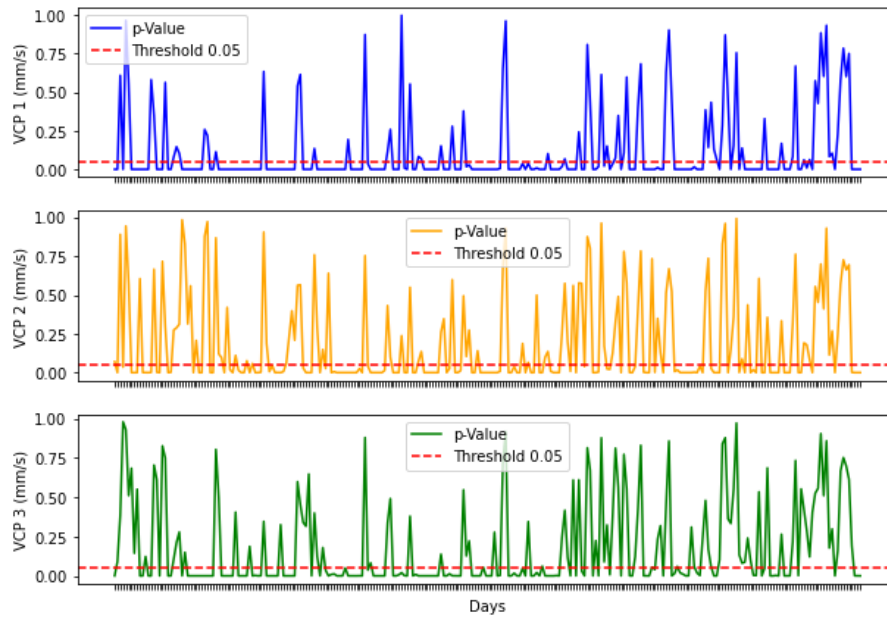


Figura 7.4: Evolução do *P-Value* ao longo do tempo (Diariamente).

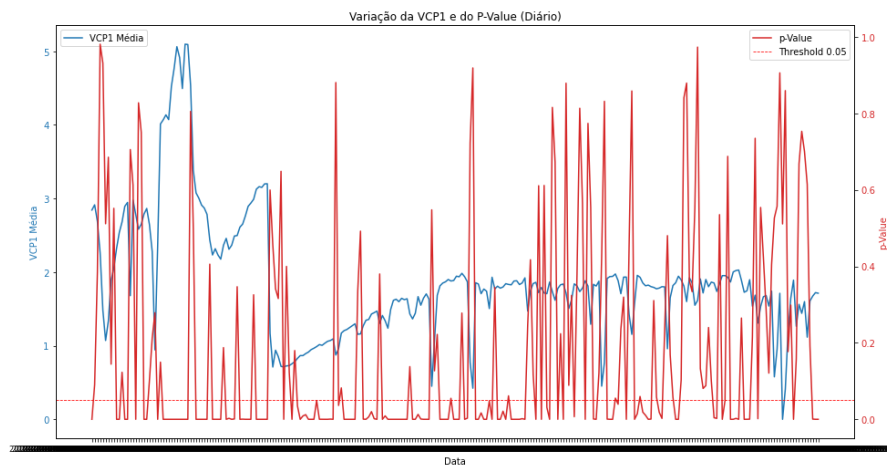


Figura 7.5: Evolução do *P-Value* Diariamente com Sobreposição (VCP1).

identificação de nenhuma relação entre estas variações. A janela temporal dos mesmos ainda foi reduzida, mas as conclusões mantiveram-se.

7.3 Impacto dos *Outliers* no *P-Value*

Os *outliers* são dados que se diferenciam drasticamente de todos os outros, ou seja, valores que fogem da normalidade e que podem causar anomalias [19]. Estes, na ausência de dados devidamente marcados em relação aos momentos em que ocorrem as falhas, poderão ser indicadores das mesmas.




Figura 7.6: Evolução do P-Value Diariamente com Sobreposição (VCP2).




Figura 7.7: Evolução do P-Value Diariamente com Sobreposição (VCP3).




Figura 7.8: Identificação dos Valores Discrepantes.

7.3.1 Definição dos Outliers

Definiu-se então que um valor considerado discrepante seria um valor 200% superior ao valor da média registrado em cada uma das variáveis ao longo da série temporal.

Posto isto, identificaram-se cinco dias na série temporal identificada onde se verificou a presença de valores discrepantes, como podemos verificar na Figura 7.8.

A Figura 7.8 mostra os valores discrepantes marcados com caixas delimitadoras, que correspondem às seguintes datas e variáveis:


- 2018-03-06 (VCP 3);
- 2018-05-16 (VCP 2);
- 2018-06-08 (VCP 1);
- 2018-07-17 (VCP 1);
- 2018-09-25 (VCP 1).

Após a identificação das datas e variáveis anteriores, decidiu-se então perceber o comportamento do *P-Value* nas semanas e dias em volta das mesmas.


7.3.2 Análise dos Outliers

Em relação ao primeiro dia identificado (2018-03-06), podemos visualizar a variação do *P-Value* semanal e diariamente na Figura 7.9, durante o mês de março. Verificamos

que há um aumento semanal do valor do *P-Value* da primeira para a segunda semana, de cerca de 0.5 unidades, que inclui o dia identificado. No entanto, analisando o gráfico com os valores diários, observamos um longo período (2018-03-02 — 2018-03-11) em que o *P-Value* se mantém com o valor 0.0 unidades, atingindo um pico no dia 12. Tendo sido observado o valor discrepante no dia 6, o gráfico com os valores diários não mostra qualquer fenómeno relativamente ao mesmo.



(a) Variação Semanal do *P-Value* em março 2018.




(b) Variação Diária do *P-Value* em março 2018.


Figura 7.9: Variação do *P-Value* em março 2018.

Quanto ao segundo dia identificado (2018-05-16), podemos visualizar a variação do *P-Value* semanal e diariamente na Figura 7.10, durante o mês de maio. Analisando semanalmente, existe um aumento do valor do *P-Value* entre a segunda e terceira semanas, que inclui o dia identificado. Em relação aos dados diários, encontramos três picos superiores neste mês (dias 4, 12 e 20), sendo que no dia 16 é iniciado outro

pequeno pico (dia 17). Seja o valor discrepante referente à data 2018-05-16, mais uma vez, a análise diária não permite dizer que esses picos observados nos dias anteriores estejam diretamente relacionados.



(a) Variação Semanal do *P-Value* em maio 2018.




(b) Variação Diária do *P-Value* em maio 2018.


Figura 7.10: Variação do *P-Value* em maio 2018.

A Figura 7.11 ilustra a variação diária do *P-Value* nos meses de junho e setembro, que incluem as datas 2018-06-08 e 2018-09-25. Na primeira data, verificamos que o *P-Value* atinge um pico de cerca de 0.4 unidades nesse mesmo dia, descendo posteriormente. Também é observado um valor de quase 1.0 unidades no 23. Em relação à segunda data, semelhante à Figura 7.9 (b), verificamos que se insere num período em que o *P-Value* se manteve a 0.0 unidades.

Por último, analisando o mês de julho na Figura 7.12, verificamos um aumento semanal



(a) Variação Diária do P -Value em junho 2018.




(b) Variação Diária do P -Value em setembro 2018.

Figura 7.11: Variação P -Value em junho e setembro 2018.


do valor do P -Value entre a segunda e a terceira semanas, que inclui a data identificada (2018-07-17). Analisando diariamente, verificamos o mesmo comportamento que já tinha sido observado anteriormente nas Figuras [7.9 (b) e 7.11 (b)].

7.3.3 Aplicação de Filtros de Ruído

A origem destas variações no P -Value não conseguiu ser explicada com base nos gráficos anteriores, mas, apesar disso, podemos concluir que as variações nas variáveis têm alguma influência no comportamento do P -Value. No entanto, de maneira a consolidar esta conclusão, foram aplicados dois filtros de ruído aos dados processados diariamente: média móvel, com janelas deslizantes de 1, 3, 7 e 15 dias, seguida pela



(a) Variação Semanal do *P-Value* em julho 2018.



(b) Variação Diária do *P-Value* em julho 2018.

Figura 7.12: Variação *P-Value* em julho 2018.

aplicação do LOWESS smoother, através do método *lowess()*¹, presente na biblioteca *statsmodels*, com *frac* = 0.15. O impacto desses filtros pode ser observado nas Figuras [7.13, 7.14, 7.15].

Analisando estes gráficos individualmente, é observada alguma estabilidade do valor médio da variável VCP1 durante maior parte da janela temporal nas Figuras [7.13, 7.14], sendo que no final observa-se um aumento repentino. Ao verificarmos o comportamento do *P-Value*, é possível ver que o mesmo padrão ocorre. Além disto, na Figura 7.13, é possível observar um aumento no *P-Value* imediatamente após a subida da média da variável, sendo assim um exemplo do padrão que se pretende obter com

¹www.statsmodels.org/devel/generated/statsmodels.nonparametric.smootherslowess.lowess.html




Figura 7.13: Variação do *P-Value* e da Média da VCP1 (1-Day Rolling).




Figura 7.14: Variação do *P-Value* e da Média da VCP1 (3-Day Rolling).




Figura 7.15: Variação do *P-Value* e da Média da VCP3 (15-Day Rolling).




Figura 7.16: Variação do *P-Value* e da Média da PCP2 (1-Day Rolling).

este estudo, ou seja, quando o *P-Value* sofre uma alteração significativa devido a uma variação da amplitude da VCP.

Na Figura 7.14 também é possível ver que, antes do aumento final na média do VCP1, o *P-Value* reage duas vezes, ultrapassando o *Threshold* de 0.05 duas vezes num curto espaço de tempo. Estas Figuras permitem mostrar que a largura da janela móvel pode ter um impacto significativo nos resultados e em possíveis alarmes, caso o *P-Value* seja usado para gerar um alarme quando sobe acima de um certo limite (0.05).

Este comportamento do *P-Value* pode, mais uma vez, ser verificado na Figura 7.15, que mostra a variação da média VCP3 com janela deslizante de 15 dias. Neste caso, antes do pico negativo observado no valor médio da variável por volta da data 2018-03-13, é possível ver um aumento significativo no *P-Value*, chegando a obter 0.5 unidades. No final do mês de maio volta a verificar-se uma subida do *P-Value* acima de 0.05, ou seja, reage ao aumento consistente da variável.

Além da análise da variável VCP, por curiosidade, foi ainda testado estas últimas análises nas variáveis **TEuBA** (temperatura das bombas) e **PCP** (pressão das bombas), recolhidas nas unidades de medida °C e kPa, respetivamente, que podem ser observadas nas Figuras [7.16, 7.17].

Tal como foi verificado com a variável VCP, também são verificadas reações no comportamento do *P-Value* quando há variações significativas nas variáveis em estudo. Na Figura 7.16 observamos que, quando a PCP2 aumenta significativamente, o *P-Value* tende a acompanhar esse aumento, reagindo ainda antes de atingir o pico da variável. O mesmo é verificado na Figura 7.17, em que, por diversas vezes, o *P-Value* ultrapassa o *Threshold* de 0.05 devido a variações da variável TEuBA3.

As análises desenvolvidas permitem-nos tirar algumas conclusões, de acordo com os gráficos observados:

- A aplicação dos filtros de ruído melhorou bastante os gráficos, permitindo assim minimizar o impacto dos picos mais curtos;




Figura 7.17: Variação do *P-Value* e da Média da TEuBA3 (7-Day Rolling).

- Utilizando um certo valor, por exemplo 0.05, como alarme de uma mudança repentina, pode ser possível prever mudanças através do *P-Value*;
- O *P-Value* é universal, visto que reage da mesma forma para as diferentes variáveis estudadas (VCP, PCP, TEuBA);
- O *P-Value* permite ajudar a prever e estudar mudanças repentinas nas variáveis, mas é necessário encontrar a janela certa para cada sinal.

8 DISCUSSÃO

O *P-Value* do teste ADF é um indicador da estacionaridade de uma série temporal. No caso de equipamentos industriais, variáveis como a vibração seriam estacionárias em condições ideais. No entanto, o que normalmente acontece, é que a vibração aumenta com o aumento da carga de trabalho ou entre intervenções de manutenção. O presente estudo mostra que a análise do *P-Value* pode ser um método promissor para detetar tendências, ou até mesmo outliers, nos sinais de vibração, temperatura e pressão de três bombas industriais.

Ao longo do desenvolvimento deste trabalho, não foram encontradas aplicações nem desenvolvimentos deste estudo, o que torna este método uma inovação na deteção de potenciais evoluções das variáveis, de forma universal, com algumas vantagens e desvantagens, contribuindo para o alargamento de abordagens possíveis nesta área.

Algumas das vantagens encontradas com este estudo foram a definição de limites do *P-Value* para todas as variáveis, o que torna esta abordagem universal na deteção da não estacionariedade de uma variável numa determinada janela temporal, além do facto de a aplicação do teste ADF ser eficaz para trabalhar com dados ruidosos, simplificando o processo de análise. Esta presença de ruído nos dados tem algum impacto nos resultados, mas não causa falhas catastróficas.

Por outro lado, o método também apresenta algumas desvantagens, demonstradas nas análises realizadas ao longo do projeto. Uma desvantagem importante é que é necessário determinar as melhores janelas temporais, tanto para calcular o *P-Value* como para os filtros de ruído, pois diferentes tamanhos de janelas produzirão resultados diferentes e diferentes números de possíveis alarmes.

O presente trabalho deu origem a um artigo científico, submetido para uma revista internacional indexada na área da fiabilidade. Este artigo encontra-se no Anexo B.

9 CONCLUSÃO

A detecção e previsão de falhas em equipamentos industriais é uma área com elevada importância, que está sujeita a intensa investigação.

O estudo realizado ao longo deste projeto permitiu mostrar que o aumento do *P-Value* associado ao teste da estacionariedade de séries temporais, através do teste ADF, pode ser uma abordagem promissora no âmbito da previsão de falhas em equipamentos industriais. Confirmou-se também a universalidade do *P-Value*, visto que reagiu da mesma forma para diferentes variáveis, apesar de ser importante a escolha das janelas temporais e os métodos de manipulação utilizados nas séries temporais estudadas.

Em futuros projetos, deve optar-se por uma análise de dados adicionais, nomeadamente para estudar com mais profundidade o comportamento do *P-Value* em situações de falhas reais, tanto para a vibração, como para outras variáveis.

O código Python desenvolvido pode ser consultado no link em rodapé ¹.

¹<https://github.com/GitHubDinis/FaultAnalysis>

REFERÊNCIAS BIBLIOGRÁFICAS

- [1] S. Chumbar, “The crisp-dm process: A comprehensive guide,” *Medium*, 2023.
- [2] A. Martins, B. Mateus, I. Fonseca, J. T. Farinha, J. Rodrigues, M. Mendes, and A. M. Cardoso, “Predicting the health status of a pulp press based on deep neural networks and hidden markov models,” *Energies*, vol. 16, no. 6, 2023. [Online]. Available: <https://www.mdpi.com/1996-1073/16/6/2651>
- [3] Wikipédia, “Interpolação linear — wikipédia, a enciclopédia livre,” 2024, [Online; accessed 21-janeiro-2024]. [Online]. Available: https://pt.wikipedia.org/w/index.php?title=Interpola%C3%A7%C3%A3o_linear&oldid=67336906
- [4] E. OSETROV, “Lowess smoother algorithm,” *Kaggle*, 2024.
- [5] A. Estebarsari and R. Rajabi, “Single residential load forecasting using deep learning and image encoding techniques,” *Electronics*, vol. 9, p. 68, 01 2020.
- [6] Y. Zhou, X. Long, M. Sun, and Z. Chen, “Bearing fault diagnosis based on gramian angular field and densenet,” *Math. Biosci. Eng*, vol. 19, no. 12, pp. 14 086–14 101, 2022.
- [7] I. Naseer, S. Akram, T. Masood, A. Jaffar, M. A. Khan, and A. Mosavi, “Performance analysis of state-of-the-art cnn architectures for luna16,” *Sensors*, vol. 22, no. 12, 2022. [Online]. Available: <https://www.mdpi.com/1424-8220/22/12/4426>
- [8] C. Tarmanini, N. Sarma, C. Gezevin, and O. Ozgonenel, “Short term load forecasting based on arima and ann approaches,” *Energy Reports*, vol. 9, pp. 550–557, 2023, 2022 The 3rd International Conference on Power, Energy and Electrical Engineering. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S2352484723000653>
- [9] B. C. Mateus, M. Mendes, J. T. Farinha, R. Assis, and A. M. Cardoso, “Comparing lstm and gru models to predict the condition of a pulp paper press,” *Energies*, vol. 14, no. 21, 2021. [Online]. Available: <https://www.mdpi.com/1996-1073/14/21/6958>
- [10] A. P. Anupam Kumar and P. K. Kankar, “A new hybrid lstm-gru model for fault diagnosis of polymer gears using vibration signals,” *Journal of Vibration Engineering and Technologies*, Tech. Rep., 2023.

- [11] J. T. F. A. M. C. R. A. Balduino César Mateus, Mateus Mendes and H. Soltanali, "Improved gru prediction of paper pulp press variables using different pre-processing methods," *Production & Manufacturing Research*, vol. 11, no. 1, p. 2155263, 2023. [Online]. Available: <https://doi.org/10.1080/21693277.2022.2155263>
- [12] C. S. of Engineering, "Bearing data center," Case Western Reserve University, Tech. Rep., 0.
- [13] D. Neupane, Y. Kim, J. Seok, and J. Hong, "Cnn-based fault detection for smart manufacturing," *Applied Sciences*, vol. 11, no. 24, 2021. [Online]. Available: <https://www.mdpi.com/2076-3417/11/24/11732>
- [14] V. K. Sinchana N Raj and Geethanjali, "Fault diagnosis in drive end bearings using cnn-based machine learning," School of Computer Science and Engineering, Bengaluru, India, Tech. Rep., Jan. 2024.
- [15] Y. Qin and X. Shi, "Fault diagnosis method for rolling bearings based on two-channel cnn under unbalanced datasets," *Applied Sciences*, vol. 12, no. 17, 2022. [Online]. Available: <https://www.mdpi.com/2076-3417/12/17/8474>
- [16] D. Bhattacharya and M. K. Nigam, "Energy efficient fault detection and classification using hyperparameter-tuned machine learning classifiers with sensors," *Measurement: Sensors*, vol. 30, p. 100908, 2023. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S2665917423002441>
- [17] K. Al Kharusi, A. El Haffar, and M. Mesbah, "Fault detection and classification in transmission lines connected to inverter-based generators using machine learning," *Energies*, vol. 15, no. 15, 2022. [Online]. Available: <https://www.mdpi.com/1996-1073/15/15/5475>
- [18] P. Ray and D. P. Mishra, "Support vector machine based fault classification and location of a long transmission line," *Engineering Science and Technology, an International Journal*, vol. 19, no. 3, pp. 1368–1380, 2016. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S2215098615303694>
- [19] A. A. Analytics, "Outliers, o que são e como tratá-los em uma análise de dados?" *Aquarela Analytics*, 2017.

ANEXOS

Anexo A - Proposta de Projeto

Proposta de Projeto

Ano Letivo de 2023/2024
2º Semestre

Visão Computacional para Análise de Falhas em Equipamentos Industriais

SUMÁRIO

Muitas indústrias atualmente dependem de equipamentos complexos e automatizados nas suas linhas de produção. A paragem destes equipamentos, planeada ou não, pode ter um impacto significativo na produção e, portanto, na rentabilidade da empresa.

Neste projeto pretende-se explorar métodos de diagnóstico de falhas, com base nos dados recolhidos por sensores que monitorizam em tempo real um equipamento industrial.

ESTAGIÁRIO (indicar o destinatário da proposta se já estiver definido)

Número de aluno: A definir

Nome completo: A definir

RAMO (indicar o(s) ramo(s) em que se enquadra)

- ☐ Desenvolvimento de Aplicações
- ☐ Redes e Administração de Sistemas
- ☐ Sistemas de Informação

ENTREVISTA/PROCESSO DE SELEÇÃO (informar se o candidato indicado pelo

DEIS-ISEC será submetido a uma entrevista ou outro tipo de processo de seleção antes da sua admissão efetiva)

- ☐ Não
- ☐ Talvez Especificar:
- ☐ Sim Especificar:

1. ÂMBITO

O projeto/estágio enquadra-se num projeto a ser desenvolvido no ISEC, com dados reais de um equipamento industrial.

2. OBJETIVOS

O presente projeto/estágio pretende atingir os seguintes objetivos genéricos:

- Estudar o estado da arte em termos de análise de dados para deteção de falhas;
- Analisar e estudar o *dataset* disponível;
- Testar e comparar diferentes algoritmos de deteção e classificação de falhas, em particular os baseados em visão computacional.

3. PROGRAMA DE TRABALHOS

O projeto consistirá nas seguintes atividades e respetivas tarefas:

- *T1 – Estudo do problema e revisão da literatura.*
- *T2 – Estudo e caracterização do conjunto de dados disponível.*
- *T3 – Desenvolvimento de algoritmos de deteção de falhas.*
- *T4 – Análise e comparação de resultados.*

É previsto que o relatório seja desenvolvido ao longo de todo o projeto, não se considerando uma tarefa específica para essa parte.

4. CALENDARIZAÇÃO DAS TAREFAS

O plano de escalonamento dos trabalhos é apresentado em seguida:

	Meses					
Tarefas		N	N+1	N+2	N+3	N+4
T1		■	■			
T2			■	■	■	
T3				■	■	■
T4					■	■
Metas	INI		M1	M2	M3	M4

INI		Início dos trabalhos
M1	(INI + 6 Semanas)	Tarefa T1 terminada
M2	(INI + 10 Semanas)	Tarefa T2 terminada
M3	(INI + 16 Semanas)	Tarefa T3 terminada
M4	(INI + 18 Semanas)	Tarefa T4 terminada

5. LOCAL E HORÁRIO DE TRABALHO

O trabalho irá decorrer nas instalações do ISEC, ou em teletrabalho, consoante o interesse e disponibilidade do aluno. Reuniões periódicas poderão realizar-se por videoconferência ou presencialmente. O horário de referência é 09h00-18h00, flexível, cabendo ao aluno organizar-se para o bom andamento do trabalho.

6. TECNOLOGIAS ENVOLVIDAS

O desenvolvimento requer uso de Python. Podem ser utilizadas outras linguagens e tecnologias.

7. METODOLOGIA

Será criado um *dossier* do projeto, procurando-se desenvolver material relevante para o relatório desde as fases iniciais. O acompanhamento será feito através de reuniões a calendarizar, de acordo com o procedimento existente no ISEC.

8. ORIENTAÇÃO

DEIS-ISEC (caso já esteja definido):

Nome: Mateus Mendes <mmendes@isec.pt>
Categoria: Prof. Adjunto

Nome: Nuno Lavado (nlavado@isec.pt)
Categoria: Prof. Adjunto

Anexo B - Monitoring of an Industrial Equipment Vibration through Analysis of Time Series Stationarity



**Monitoring of an Industrial Equipment Vibration through
Analysis of Time Series Stationarity**

Journal:	<i>International Journal of Quality & Reliability Management</i>
Manuscript ID	Draft
Manuscript Type:	Reliability Paper
Keywords:	Time series, Stationarity, Predictive maintenance, Vibration Analysis, Stationarity Analysis
Abstract:	

SCHOLARONE™
Manuscripts

Monitoring of an Industrial Equipment Vibration through Analysis of Time Series Stationarity

July 12, 2024

Abstract

Predictive maintenance has gained importance due to industrialization. By harnessing advanced technologies like sensors and data analytics, it enables proactive interventions, preventing unplanned downtime, reducing costs, and enhancing workplace safety. It plays a crucial role in optimizing industrial operations, ensuring efficiency, reliability, and the longevity of equipment, which have become increasingly vital in the context of industrialization. The analysis of time series' stationarity is a powerful approach to study variations and trends that may indicate imminent failures in equipment, thus contributing to the effectiveness of predictive maintenance in industrial environments. The present paper explores the use of the Augmented Dickey Fuller p-value temporal variation as a possible universal method to determine trends in sensor time series and thus anticipate possible failures. The results show sensitivity of the p-value, as long as an adequate rolling window and noise filtering are used.

Keywords: Time series; Stationarity; Predictive maintenance; Vibration Analysis; Stationarity Analysis.

1 Introduction

Stopping industrial equipment on production lines is normally detrimental to the companies. Downtime means loss of production, plus costs due to stopping and restarting the equipment. This underscores the importance of predictive approaches to anticipate behaviors corresponding to potential failures that could trigger these stoppages.

In this context, predictive modeling emerges as a fundamental tool, allowing companies to anticipate equipment failures based on historical and real-time data. By employing advanced data analysis and machine learning techniques, organizations can identify hidden patterns in equipment operational data and develop accurate predictive models that alert about potential impending failures. This way it is possible to minimize unexpected equipment downtime, improve service quality for customers, and also reduce the additional cost caused by over-maintenance in preventive maintenance policies [1]. There are a variety of approaches, each with its advantages and disadvantages [2], but in all of them it is essential to follow best practices for data preparation, model training, and validation to ensure the accuracy and reliability of the predictions. Some approaches stand out for their ability to capture temporal dependencies in sequential data, which is essential for predicting equipment failures over time.

Outstanding state of the art models include recurrent neural networks, namely Long Short-Term Memory (LSTM) and Gated Recurrent Units (GRU) [3, 4, 5].

Other models are effective in modeling linear and stationary relationships in time series data, such as Autoregressive Integrated Moving Average (ARIMA) or Seasonal Autoregressive Integrated Moving Average (SARIMA), although those models are normally more efficient in short-term prediction [6, 7, 8]. It is also common to use ensemble approaches, which combine multiple models, such as Random Forests (RF) and Gradient Boosting Machines (GBM) [9, 10]. However, each model should be developed according to specific needs and characteristics of the problems.

Prediction of future sensor values alone is not sufficient to identify the trends automatically. Predictive models only forecast the future, but additional tools are needed to classify the features and determine whether the patterns that are being anticipated are normal or abnormal. The classification is normally done through classical machine learning models, such as neural networks, Support Vector Machines and other classifiers [11, 12].

The present work aims to detect possible failures in an industrial wood chips pump. The methodology consisted of analyzing the p-value produced by the Augmented Dickey Fuller (ADF) test for stationarity. The ADF test establishes that a p-value above a certain level, typically 0.05, indicates a possibly non-stationary time series. Hence, the hypothesis is that a trend which may lead to an equipment failure might be detected by observation of the p-value of a time series in near-real time using a rolling window for the test. Specific patterns of increase, decrease or large amplitude variations might reveal a possibly approaching failure in the equipment. These patterns must, therefore, be analysed aiming to prevent failures from happening. To the best of our knowledge no previous predictive maintenance study has been reported using the variation of ADF test. However, this method can be a universal approach for all variables which are stationary in normal conditions, offering great potential for predictive maintenance systems.

Section 2 describes the state of the art. Section 3 describes the materials and methods used. Section 4 shows the results obtained. Section 5 presents a balance and comparison of the results to the state of the art. Section 6 draws some conclusions and future work directions.

2 Literature review

Fault prediction in industrial equipment is an area of research and practice that encompasses a wide range of approaches and methodologies. Given the complexity of industrial systems and the diversity of factors that can lead to faults, there is no single approach that is universally applicable. Instead, engineers and researchers have explored a variety of techniques and strategies to anticipate, avoid and mitigate equipment failures [13].

Statistical models aim at analysing the behaviour of random variables based on recorded data. For predictive maintenance, statistical models are used to determine the current degradation and the expected remaining life of the equipment. This type of models are often implemented in multi-model approaches [14].

Jie Zhao *et al.* [15] present a novel methodology to use Auto-Regressive

Moving Average (ARMA). Instead of using most common data transformation methods, they developed their own method, by creating a transfer function, and took the transformed sequence as the input data to build an ARMA model. They achieved a Mean Absolute Percentage Error (MAPE) 2.48%, which is lower than the ARMA model with traditional methods.

ARIMA is the most common forecast model in time series, due to the adaptability of linear patterns amongst all time series strategies, according to Chafak Tarmanini *et al.* [16]. Based on daily real electricity load data for 709 individual households that were randomly chosen over an 18 month period, they compared the performance between two forecasting methods: ARIMA and Artificial Neural Network (ANN). After tests, ANN's MAPE was 1.80% and ARIMA's approximately 2.61%.

In order to prove the good performance applied to problems related to anomaly detection and technological parameter forecasting of the ARIMA algorithm, using sparse data obtained from an urban sewer system, Karthick Thiagarajan *et al.* [17] developed a model and obtained appealing results. In a time span of 30 days, during which 24 days were used for training, they achieved a Mean Absolute Error (MAE) of approximately 0.0962.

Jing Xu and Yongbo Zhang [18] developed a model aiming to study quality prediction in power grid equipment based on key inspection parameters. By gathering live monitoring data from power grid equipment and creating an intelligent predictive alerting algorithm using time series and trend analysis, they achieved MAPE of 5.62% for leakage current and 4.16% for resistive current.

Luigi De Simone *et al.* [19] proposed an LSTM methodology for predictive maintenance of railway rolling stock equipment. As the dataset contained some imperfections, they developed an algorithm for filtering the spikes found and another one for standardizing it. They also used 10-fold cross-validation and Adaptive Moment Estimation (ADAM), and obtained the following results: 0.0184 MAE for a 60 minutes predicted time window, aggregating low and high severity diagnostic events (L&H). For high severity diagnostic events only (H), they achieved 0.0008 MAE.

Based on supervisory control and data acquisition (SCADA) data, Wisdom Udo and Yar Muhammad developed eight models using extreme gradient boosting (XGBoost) and LSTM to build the characteristics behaviour of critical wind turbines components [20]. They tested on two real case studies regarding six different wind turbines, with the aim of predicting gearbox bearing temperature and obtained MAPE between 0.8% and 6.2%.

Hansika *et al.* [21] propose that RNN's have shown to be promising options for prediction tasks, often surpassing the current state-of-the-art statistical benchmarks in the field. One of the existing types of RNN's is GRU. Mateus *et al.* [22] have employed neural networks to develop two models aimed at predicting the behavior of an industrial paper press. Their achievement lies in accurately forecasting the press' behavior over a 30-day period, achieving a MAPE of less than 10% utilizing GRU.

Mateus *et al.* [22] also developed a model using LSTM to compare with a GRU network. Using the same training and test data in both experiments, with changes such as different resample rates, different layer sizes, and different activation functions in the hidden layer, they concluded the existence of some instability in the LSTM model, with its results varying significantly.

Martins *et al.* [23] also developed a model using GRU, successfully predict-

Table 1: Comparison of different methods used for time series prediction

Authors	Model	MAPE	MAE
Mateus <i>et al.</i> [22]	GRU	10.00%	-
Martins <i>et al.</i> [23]	GRU	2.79%	-
Mateus <i>et al.</i> [24]	GRU	1.2%	-
Xu & Zhang [18]	LSTM	5.16%, 4.16%	-
De Simone <i>et al.</i> [19]	LSTM	-	0.0184 (L&H), 0.0008 (H)
Wisdom & Yar [20]	LSTM	0.8% - 6.2%	-
Jie Zhao <i>et al.</i> [15]	ARMA	2.48%	-
Yamak <i>et al.</i> [25]	ARIMA	2.76%	-
Tarmanini <i>et al.</i> [16]	ARIMA, ANN	2.61%, 1.80%	-
Yamak <i>et al.</i> [25]	ARIMA	-	0.0962

GRU - Gated Recurrent Unit, LSTM - Long Short-Term Memory, ARMA - Autoregressive Moving Average, ARIMA - Autoregressive Integrated Moving Average, ANN - Artificial Neural Network

ing, within a 7-day timeframe and MAPE of 2.79%, the three states classified by the Hidden Markov Model and the observable states obtained from clustering. The methodology also involved the use of Principal Component Analysis (PCA) and K-Means algorithm in data clustering.

To examine the most efficient pre-processing approaches for predicting sensory data trends based on GRU neural networks, Mateus *et al.* [24] developed a model that can anticipate future values with MAPE of 1.2%. They proved that it is possible to forecast future behavior of industrial paper pulp presses up to 30 days in advance.

With the variety of models and ways to predict time series values, and in turn equipment failures, Peter T. Yamak *et al.* [25] conducted a study on the performance of LSTM, GRU, and ARIMA models. They use data from Bitcoin transactions, from a Crypto data download website. Data were normalized, forced stationarity, trend and seasonality were removed. All models were tested over a time span of 500 days, yielding the following MAPE results: LSTM 6.80%, GRU 3.97% and ARIMA 2.76%, with this last being the best and lasting the least amount of time.

Table 1 shows a comparison of some relevant approaches to time series prediction and fault detection, including both classical statistical models and the modern approaches based on deep neural networks. As the table shows, predictive models already achieve very reasonable accuracy, with errors inferior to 10 %. Nonetheless, these predictions still need additional analysis in order to determine a potential failure. No studies were founded based on the analysis of the p-value to determine ongoing trends, as aimed in the present study.

3 Materials and Methods

The Cross Industry Standard Process for Data Mining (CRISP-DM) methodology was followed during the research. The first steps are described in the present section, the analysis of results is described in Section 4. Deployment is left as future work.

Table 2: Statistical data related to 2017, 2018 and 2019, respectively.

Variable	VCP 1	VCP 2	VCP 3	
AF	516k; 517k; 508k	487k; 517k; 511k	512k; 517k; 497k	
Mean	0.69; 1.03; 1.47	2.13; 2.04; 1.89	1.03; 1.85; 1.54	
STD	0.84; 0.57; 0.54	0.47; 0.54; 0.67	0.46; 0.81; 0.76	
Min	-0.05; -0.049; -0.05	-0.07; -0.04; -0.04	-0.04; -0.01; -0.05	AF
25%	0.56; 0.69; 1.21	1.96; 1.87; 1.55	0.81; 1.53; 1.07	
50%	0.67; 0.85; 1.52	2.25; 2.12; 1.99	0.96; 1.81; 1.36	
75%	0.84; 1.20; 1.85	2.49; 2.37; 2.34	1.11; 2.03; 1.74	
Max	5.34; 23.90; 11.58	25.11; 19.89; 10.03	2.60; 9.88; 20.69	

– Absolute Frequency, STD – Standard Deviation, Min – Minimum, Max – Maximum, VCP n – Vibration of Chip Pump n

3.1 Experimental setup

In the experimental part, the Python programming language was used, in the multiplatform open-source integrated development environment (IDE) for scientific programming called Spyder. Additionally, in the development of this project, the following libraries were used: *pandas*, *numpy*, *matplotlib*, *pickle*, *statsmodels*, and *seaborn*.

3.2 Dataset

The dataset used in this project contains sensor data from three industrial wood chips pumps, which are operating in a large Portuguese paper industry. The data were collected by a set of sensors installed in the pumps and logging readings with 1 minute period sampling rate. The dataset contains data for years 2017, 2018, and 2019. The number of variables monitored is 31, but for simplicity of the analysis only three were used in this project: vibration of chip pump 1 (VCP 1), vibration of chip pump 2 (VCP 2) and vibration of chip pump 3 (VCP 3). Vibration was chosen because it of its importance for condition monitoring. It is one of the most telling variables and also one of the most difficult to analyse because of the influence of noise. Increasing vibration in an industrial equipment is a serious risk, so this is one variable where stationarity analysis can be more important.

Some statistical results from different years and different chip pumps, taken from the provided dataset, are shown in Table 2. As the table shows, there are some negative numbers, which obviously correspond to noise and outliers in the data. The table also shows that VCP1 has the lowest mean and the highest standard deviation in 2017, which means probable problems along the year. VCP2 has the highest mean of the three chip pumps. It also reaches the highest values in 2017 and 2018, which means it may need maintenance interventions to improve its working condition and prevent potential failures.

Table 2 also shows there are some missing samples, otherwise AF (absolute frequency) would be 525k for all those variables, considering the sampling period is 1 min. Some of the missing samples correspond to periods of planned maintenance, when the equipment and sensors are turned off. Other missing values, however, correspond to failures in the process of reading or recording the data. When this happens, there are still records in the database, however they

Table 3: Missing values from 2017, 2018 and 2019 data.

Year	VCP1	VCP2	VCP3
2017	8 964	37 721	13 130
2018	8 026	7 916	8220
2019	16 893	14 555	28 027

Table 4: Statistical data related to 2017, 2018 and 2019 data, after downsampling.

Var	VCP1	VCP2	VCP3
AF	103 549; 103 734; 101 886	97 883; 103 752; 102 354	102 715; 103 692; 99 658
Mean	0.69; 1.03; 1.47	2.14; 2.04; 1.89	1.03; 1.85; 1.54
SD	0.28; 0.56; 0.53	0.88; 0.52; 0.65	0.45; 0.80; 0.74
Min	-0.05; -0.05; -0.05	-0.05; -0.04; -0.04	-0.02; -0.01; -0.01
25%	0.58; 0.72; 1.21	2.00; 1.89; 1.56	0.83; 1.55; 1.07
50%	0.67; 0.85; 1.51	2.25; 2.12; 2.00	0.96; 1.82; 1.36
75%	0.84; 1.12; 1.84	2.47; 2.36; 2.34	1.08; 2.00; 1.73
Max	4.53; 21.28; 5.81	24.41; 6.63; 7.45	2.55; 5.94; 17.25

AF - Absolute Frequency, STD - Standard Deviation, Min - Minimum, Max - Maximum

are incomplete and may pose challenges to data analysis. Table 3 summarizes the number of missing values that may need attention during the data analysis process.

3.3 Data Preparation

In order to make the dataset less extensive, and reduce noise at the same time, downsampling was performed, changing the period to 5 min instead of the original 1 min—*i.e.*, the mean of each period of 5 minutes was taken from the original dataset. Thus, the dataset was reduced to one fifth, approximately 100k rows instead of approximately 500k. Table 4 shows a summary of the statistical parameters of the dataset after downsampling.

After dataset reduction, it is clear that the average values remained largely unchanged, but the maximum values were affected. After further analysis, some periods were identified as candidates for subsequent analysis, given their small percentage of missing values and their temporal extent. The following ranges were selected:

- Range 1 (R1): 2017-11-05 — 2018-01-20;
- Range 2 (R2): 2018-02-04 — 2018-10-27;
- Range 3 (R3): 2018-11-04 — 2019-02-16.

Those periods are of interest because of the low number of missing data samples. Table 5 shows a summary of the statistical parameters of those intervals. As the table shows, there are still some missing points in the second interval, so they were imputed using linear interpolation. Moreover, it is also possible to notice a difference between the values observed in the second interval in absolute frequency, due to its longer time span.

Table 5: Statistical data related to previous intervals (R1; R2; R3), respectively.

Var	VCP 1	VCP 2	VCP 3
AF	22 176; 76 479; 30 240	22 176; 76 525; 30 240	22 176; 76 507; 30 240
Mean	0.65; 0.86; 1.92	1.98; 2.05; 2.09	1.83; 1.87; 1.56
SD	0.18; 0.40; 0.43	0.43; 0.53; 0.48	0.36; 0.89; 0.38
Min	-0.05; -0.05; -0.04	-0.04; -0.04; -0.04	-0.01; -0.01; -0.01
25%	0.59; 0.71; 1.91	1.89; 1.88; 2.03	1.80; 1.42; 1.48
50%	0.66; 0.83; 2.02	2.09; 2.12; 2.20	1.87; 1.81; 1.64
75%	0.73; 0.97; 2.11	2.21; 2.39; 2.33	1.96; 2.01; 1.77
Max	1.97; 21.28; 3.27	2.69; 6.63; 2.94	2.37; 5.94; 2.18

AF - Absolute Frequency, STD - Standard Deviation, Min - Minimum, Max - Maximum

Table 6: Statistical data related to the second interval (R2), after linear interpolation.

Var	VCP 1	VCP 2	VCP 3
AF	76 608	76 608	76 608
Mean	0.87	2.05	1.87
SD	0.43	0.53	0.89
Min	-0.05	-0.04	-0.01
25%	0.71	1.88	1.42
50%	0.83	2.12	1.81
75%	0.97	2.39	2.01
Max	21.28	6.63	5.94

AF - Absolute Frequency, STD - Standard Deviation, Min - Minimum, Max - Maximum

As shown in the previous Table 6, after applying linear interpolation to the second time interval, the values have hardly changed.

3.4 Methods

As mentioned in Section 1, the main objective of this study is to understand the variation of the p-value through stationarity tests, namely using the ADF test. This test shows if the time series can be considered stationary or not. It consists in testing the null hypothesis, which states that there is a unit root in the time series sample and therefore the series is not stationary. If the null hypothesis cannot be rejected, then it is not possible to reject the existence of a unit root and the series is therefore non-stationary [26]. The lower the test's p-value, the higher the rejection of the null hypothesis. The larger the p-value, the higher the acceptance of non-stationarity.

The ADF test is applied to the time series model:

$$\Delta y_t = y_t - y_{t-1} = \alpha + \beta t + \gamma y_{t-1} + \delta_1 \Delta y_{t-1} + \dots + \delta_{p-1} \Delta y_{t-p+1} + \varepsilon_t,$$

where y_t is the time series, α is a constant, β the coefficient on a time trend, p the lag order of the autoregressive process, t is time, δ_j are coefficients and ε is an error. γ is the coefficient more directly associated with stationarity. Performing a linear regression of Δy_t against t and t_{t-1} , if $\gamma = 0$, then the process is a random walk, otherwise the series is non-stationary.

Based on the results obtained from the analyses of the previous time series, it was concluded that the time series corresponding to the interval from 2018-04-02 to 2018-10-27 would be the most suitable for the modeling phase, considering its temporal extent and statistical quality properties.

4 Results

4.1 Variable Analysis

Through the individual analysis of the variables, an attempt was made to understand their behavior along time. Figure 1 shows plots of the three variables chosen, for the year 2018. Regarding variable VCP 1, it is possible to observe some regularity and stability over time, but it also presents some discrepant values, which may happen for different reasons. As for variable VCP 2, it exhibits a seasonal behavior due to the repetition of patterns throughout the time series. Notably, there are nearly zero values and values associated with the mean value. Variable VCP 3, between February and May, demonstrates a dynamic behavior with some randomness in values. From there, similar to the analysis conducted on the behavior of variable VCP 2, some seasonal patterns start to emerge. The charts give an idea of the long-term behaviour of the variables, but it is clear the signals are very noisy and it is difficult to identify clear patterns just from visual information.

4.2 Seasonal Decomposition

Individual decomposition of the data was performed focusing on trend, seasonality and residual components. Previous analysis of the charts shows that the

2018 Data - Chip Pump Vibration




Figure 1: Data plots for year 2018.




Figure 2: Seasonal Decomposition of variable VCP 1

series do not vary too much along time, but even so they may contain some seasonal component, additive being more probable than multiplicative considering that the average and standard deviation do not suffer large changes over time. Therefore, seasonal decomposition was performed using the additive model. For the period, different values were tried. The value 100 was used to produce the charts shown in Figure 2. As the figure shows, the variable VCP 1 exhibits an absence of significant trends in the time series, there are no clear upward or downward movements. Additionally, it's worth noting the presence of reduced seasonality, for the seasonal component is fluctuating between the values of -0.02 and 0.03.

Figure 3 shows the seasonal decomposition of variable VCP 2. Again, despite the presence of numerous oscillations in the trend, crystal clear long-term growth and decline movements are not visible. The oscillations show there is more noise in this signal than in VCP 1, but the noise does not show clear patterns that could be identified at this point. Despite the noise and small amplitude of the most mid-term trend variations, the chart seems to show that there is a growing trend until mid April, followed by a sudden decline. And then after this decline there is a slowly growing trend until late September, again followed by a decline, this time with a period of instability. These faint variations along time may be important for further analysis. As for the seasonality, it exhibits similarities to the behavior observed previously in variable VCP 1, so there are no clear seasonal components of significant amplitude.

Regarding variable VCP 3, seasonal decomposition is shown in Figure 4. The charts show the peculiar characteristics of the signal, different from the VCP 1 and 2. Again, the seasonal component is negligible. The trend is variable in the first months and more stable after April. Until May, a quite pronounced but unstable trend is observed, which denotes problems in the equipment's normal operation. At the end of April, something changed and the trend decreased suddenly, slowly increasing in subsequent months.




Figure 3: Seasonal Decomposition of variable VCP 2




Figure 4: Seasonal Decomposition of variable VCP 3

Table 7: Results of the ADF Test

Variable Analyzed	VCP1	VCP2	VCP3
ADF Statistic test	-18.90	-11.43	-6.16
p-value	0.0	6.53×10^{-21}	7.18×10^{-08}

4.3 Stationarity Analysis

The ADF test was employed in order to analyse stationarity of the signals. Table 7 shows the p-value for all the period under analysis (R2), for the three pumps. As the table shows, all ADF's statistic test values are strongly negative, indicating strong evidence against the null hypothesis of non-stationarity. In other words, the time series are proven to be stationary in the period, which is according to visual evidence when looking at the charts 1, 2, 3 and 4 and also the information that comes from the factory: the pumps receive periodic maintenance interventions, so that the vibrations are kept at safe levels along time.

Nonetheless, when the analysis is performed in smaller time windows, stationarity may not be guaranteed, as according to the initial research question of the present research. The most important question, however, is what window sizes will work to show relevant non-stationarity of the time series, if any. Considering the project's objectives, it was decided to experiment with two distinct size rolling windows: weekly and daily. This segmentation aims to obtain information that would lead to a more holistic approach.

The weekly variation of the p-value throughout the time series is illustrated in Figure 5. The figure shows that the p-value varies from approximately zero to values above 0.75 in VCP 2 and 0.6 in VCP 1 and VCP 3. This indicates that there are weeks when the vibration follows a non-stationary path, which is the pattern being sought in the present research.

An example of the daily variation of the p-value throughout the time series is illustrated in Figure 6. As the figure shows, daily variations exhibit constant fluctuations, which make any analysis and monitoring very difficult to perform. The weekly signals produce more stable results, but even so there is certainly a lot of noise, while a more stable signal is required for more confidence in the results.

4.4 Impact of Outliers in the p-value

Discrepant values are often called outliers. They are normal in industrial sensor readings and they have an impact on the data analysis process, for they affect data average, standard deviation and many other statistical characteristics of the series.

A relation between discrepant data and the p-value was also sought. We are particularly interested in outliers because in the absence of labelled data about failures' true timestamps, outliers are possible indicators of failures. They may be sources of true or false positives.

In this study, a discrepant value was defined as 200% higher than the mean recorded for each analyzed variable. In our data 5 days of discrepant values were identified. Figure 7 shows the discrepant values marked with bounding boxes. They correspond to the following dates:




Figure 5: Evolution of the p-value over time using weekly moving windows, from February to October




Figure 6: Variation of P-Value and Variable VCP3 Daily with overlap





Figure 7: Discrepant values marked with bounding boxes.


- 2018-03-06 (VCP 3);
- 2018-05-16 (VCP 2);
- 2018-06-08 (VCP 1);
- 2018-07-17 (VCP 1);
- 2018-09-25 (VCP 1).

Performing a more specific analysis of the p-value values on the different dates identified, it is possible to observe some variations in the p-value during or around the week that includes the date of the discrepant values. As an example, Figure 8 shows the weekly and daily p-values for VCP 3, where a spike in vibration was observed at 6 March. As the figure shows, there is an increase in the p-value in the first week of March, followed by a steady decrease until the end of the month. The daily chart shows the highest p-values were registered in days 12, 16 and 30—in other words, after the discrepant was registered. These values can be compared in Figure 6, which shows the variation of the p-value and the mean of the variable VCP 3 corresponding to the identified day, and which highlights some peaks of the p-value over four months, including March.

The sources of the spikes may be numerous, and during the present study it was not possible to explain them. Hence, the conclusion from these observation is that outliers have an influence on the p-value, but whether they are true or false positives, regarding fault diagnosis, is left as future work when more data are available.



(a) P-Value Weekly Variation on March 2018



(b) P-Value Daily Variation on March 2018

Figure 8: P-Value Variation on March 2018

4.5 Minimizing noise

In order to minimize the impact of the discrepant data in the variation of the p-value, two noise filters were applied. They consisted of applying rolling average, with sliding windows of 1, 3, 7 or 15 days, followed by the application of a LOWESS filter with $frac = 0.15$. The impact of those filters can be observed in Figures [9, 10 and 11].

Figures [9 and 10] show a portion of VCP1 signal, smoothed with rolling averages of 1 and 3-day windows, respectively, and then LOWESS with fraction of 15%. Analyzing figures [9 and 10], it is possible to observe some stability in the mean value of VCP1, throughout most of the time window. However, towards the end of the window, there is a sudden increase. Looking at the variation of the p-value, it is possible to see that the same pattern occurs. Additionally, in Figure 9, it is possible to observe an increase in the p-value immediately after the mean of the variable rises. This shows one example of the pattern being sought, when the series becomes non-stationary because of an increasing rolling average due to increased vibration amplitude.

In Figure 10, it is also possible to see that before the final increase in the VCP1 mean, the p-value reacts twice, rising above the threshold value of 0.05 twice in a short time span. This is the same signal as in Figure 9. The figures show that the width of the rolling window can have a significant impact in the results and possible alarms generated, in case the p-value is used to generate an alarm when it rises above a certain threshold.

This same p-value behavior can also be observed in Figure 11, showing vibration for VCP3 with rolling average of 15 days. In this case, before a negative peak in the mean value of the variable is observed, it is possible to see a signifi-




Figure 9: P-Value and VCP1 Mean Variation (1-Day Rolling Average)




Figure 10: P-Value and VCP1 Mean Variation (3-Day Rolling Average)




Figure 11: P-Value and VCP3 Mean Variation (15-Day Rolling Average)

cant increase in the p-value followed by a sudden drop. The p-value reacted to a spike in vibration that lasted several days, and at the end of May it also went above 0.05, reacting to a consistent increase of vibration levels.

In summary, the pictures show:

1. The impact of short spikes in the p-value, when no noise-filtering methods are used. The p-value responds to the spikes and can generate true or false positives, more data being necessary to determine which is the case.
2. Applying noise-filtering methods such as rolling average and LOWESS filter, the impact of short spikes is minimized. The size of the rolling window has a direct impact on the number of times the p-value crosses the significance threshold defined.

5 Discussion

The p-value of the ADF test is one indicator of the stationarity of a time series. In the case of industrial equipment, some variables, such as vibration, would be stationary in ideal conditions. However, what normally happens is that vibration increases with increased workload or between maintenance interventions. The present research shows that analysis of the p-value may be a promising method to detect trends, or even outliers, in the vibration signals of three industrial pumps.

To the best of the authors' knowledge this method has never been tried before. Nonetheless, analysis of the p-value could have several advantages compared to other methods of detecting and predicting possible faults:

- One advantage is that it is known that a p-value above 0.05 indicates non-stationarity of the series. This threshold is easier to establish than fixing limits for each variable. So this could be a kind of universal approach to detect non-stationarity of a variable in a given time window.

- Another advantage is that the ADF test is adequate to work with noisy data, simplifying the analysis process. The presence of noise in the data has some impact in the results but does not cause a catastrophic failure of the method.

On the other hand, the method also shows some drawbacks, demonstrated in the results of the experimental work. One important drawback is that it is necessary to determine the best time windows, both for calculating the p-value and for the noise filters, if they are applied, because different window sizes will produce different results and different numbers of possible alarms.

6 Conclusion

Fault detection and prediction in industrial equipment is an important area, subject to heavy research. To the best of the authors' knowledge, analysis of the p-value of the ADF test of a time series is a novel approach for monitoring and determining trends in the state of an equipment. The hypothesis was further investigated by analysis of the p-value of three time series, using rolling windows of different sizes to calculate the p-value and also to apply noise-filtering techniques to stabilize the results obtained.

The results showed a stable increase in the p-value when there are large variations in the vibration of the chip pumps. Equipment prognostic and fault prediction using the p-value is an appealing idea, because it can be a universal method, simpler than defining limits for each variable.

Future work requires analysis of additional data, namely to study in deeper detail the behaviour of the p-value in situations of actual faults, both for vibration and other variables.

References

- [1] J. Wang, C. Li, S. Han, S. Sarkar, and X. Zhou. Predictive maintenance based on event-log analysis: A case study. *IBM Journal of Research and Development*, 61(1):11:121–11:132, Jan 2017.
- [2] Tianwen Zhu, Yongyi Ran, Xin Zhou, and Yonggang Wen. A survey of predictive maintenance: Systems, purposes and approaches, 2024.
- [3] Balduino César Mateus, Mateus Mendes, José Torres Farinha, Rui Assis, and António Marques Cardoso. Comparing lstm and gru models to predict the condition of a pulp paper press. *Energies*, 14(21), 2021.
- [4] Zhongyang Han, Jun Zhao, Henry Leung, King Fai Ma, and Wei Wang. A review of deep learning models for time series prediction. *IEEE Sensors Journal*, 21(6):7833–7848, 2019.
- [5] Hongju Yan and Hongbing Ouyang. Financial time series prediction based on deep learning. *Wireless Personal Communications*, 102:683–700, 2018.
- [6] João Antunes Rodrigues, José Torres Farinha, Mateus Mendes, Ricardo Mateus, and António Marques Cardoso. Short and long forecast to implement predictive maintenance in a pulp industry. *Eksploracja i Niezawodność*, 24(1), 2022.

- [7] Yangdong Liu, Yizhe Wang, Xiaoguang Yang, and Linan Zhang. Short-term travel time prediction by deep learning: A comparison of different lstm-dnn models. In *2017 IEEE 20th international conference on intelligent transportation systems (ITSC)*, pages 1–8. IEEE, 2017.
- [8] Benjamin Lindemann, Timo Müller, Hannes Vietz, Nasser Jazdi, and Michael Weyrich. A survey on long short-term memory networks for time series prediction. *Procedia Cirp*, 99:650–655, 2021.
- [9] Nurkamilya Daurenbayeva, Almas Nurlanuly, Lyazzat Atymtayeva, and Mateus Mendes. Survey of applications of machine learning for fault detection, diagnosis and prediction in microclimate control systems. *Energies*, 16(8), 2023.
- [10] Anam Abid, Muhammad Tahir Khan, and Javaid Iqbal. A review on fault detection and diagnosis techniques: basics and beyond. *Artificial Intelligence Review*, 54(5):3639–3664, 2021.
- [11] João RodRigues, Ines Costa, J Torres Farinha, Mateus Mendes, and Luis Margalho. Predicting motor oil condition using artificial neural networks and principal component analysis. *Eksploratacja i Niezawodność*, 22(3), 2020.
- [12] Dubravko Miljković. Fault detection methods: A literature survey. In *2011 Proceedings of the 34th International Convention MIPRO*, pages 750–755, 2011.
- [13] Rahman Dashti, Mohammad Daisy, Hamid Mirshekali, Hamid Reza Shaker, and Mahmood Hosseini Aliabadi. A survey of fault prediction and location methods in electrical energy distribution networks. *Measurement*, 184:109947, 2021.
- [14] Juan José Montero Jimenez, Sébastien Schwartz, Rob Vingerhoeds, Bernard Grabot, and Michel Salaün. Towards multi-model approaches to predictive maintenance: A systematic literature survey on diagnostics and prognostics. *Journal of Manufacturing Systems*, 56:539–557, 2020.
- [15] Jie Zhao, Limei Xu, and Lin Liu. Equipment fault forecasting based on arma model. In *2007 International Conference on Mechatronics and Automation*, pages 3514–3518, Aug 2007.
- [16] Chafak Tarmanini, Nur Sarma, Cenk Gezeğin, and Okan Ozgonenel. Short term load forecasting based on arima and ann approaches. *Energy Reports*, 9:550–557, 2023. 2022 The 3rd International Conference on Power, Energy and Electrical Engineering.
- [17] Karthick Thiyagarajan, Sarath Kodagoda, and Linh Van Nguyen. Predictive analytics for detecting sensor failure using autoregressive integrated moving average model. In *2017 12th IEEE Conference on Industrial Electronics and Applications (ICIEA)*, pages 1926–1931, June 2017.
- [18] Jing Xu and Yongbo Zhang. Device fault prediction model based on lstm and random forest, 2024.

- [19] Luigi De Simone, Enzo Caputo, Marcello Cinque, Antonio Galli, Vincenzo Moscato, Stefano Russo, Guido Cesaro, Vincenzo Criscuolo, and Giuseppe Giannini. Lstm-based failure prediction for railway rolling stock equipment. *Expert Systems with Applications*, 222:119767, 2023.
- [20] Wisdom Udo and Yar Muhammad. Data-driven predictive maintenance of wind turbine based on scada data. *IEEE Access*, 9:162370–162388, 2021.
- [21] Hansika Hewamalage, Christoph Bergmeir, and Kasun Bandara. Recurrent neural networks for time series forecasting: Current status and future directions. *International Journal of Forecasting*, 37(1):388–427, 2021.
- [22] Balduino César Mateus, Mateus Mendes, José Torres Farinha, Rui Assis, and António Marques Cardoso. Comparing lstm and gru models to predict the condition of a pulp paper press. *Energies*, 14(21), 2021.
- [23] Alexandre Martins, Balduino Mateus, Inácio Fonseca, José Torres Farinha, João Rodrigues, Mateus Mendes, and António Marques Cardoso. Predicting the health status of a pulp press based on deep neural networks and hidden markov models. *Energies*, 16(6), 2023.
- [24] José Torres Farinha António Marques Cardoso Rui Assis Balduino César Mateus, Mateus Mendes and Hamzeh Soltanali. Improved gru prediction of paper pulp press variables using different pre-processing methods. *Production & Manufacturing Research*, 11(1):2155263, 2023.
- [25] Peter T. Yamak, Li Yujian, and Pius K. Gadosey. A comparison between arima, lstm, and gru for time series forecasting. In *Proceedings of the 2019 2nd International Conference on Algorithms, Computing and Artificial Intelligence*, ACAI '19, page 49–55, New York, NY, USA, 2020. Association for Computing Machinery.
- [26] Angeliki Menegaki. Chapter 2 - stationarity and an alphabetical directory of unit roots often used in the energy-growth nexus. In Angeliki Menegaki, editor, *A Guide to Econometrics Methods for the Energy-Growth Nexus*, pages 31–61. Academic Press, 2021.



**Instituto Superior
de Engenharia**

Politécnico de Coimbra