

RELATÓRIO DE PESQUISA

LICENCIATURA EM ENGENHARIA INFORMÁTICA

SISTEMAS DE INFORMAÇÃO III – 3º ANO

Dinis Meireles de Sousa Falcão | a2020130403@isec.pt

Miguel Diogo Baptista Agostinho | a2018016224@isec.pt

Tiago Alexandre Pais Dias | a2019126344@isec.pt

ÍNDICE

INTRODUÇÃO	3
OBJETIVOS	3
O QUE É UM DATA WAREHOUSE?	3
CONSTITUIÇÃO DE UM DATA WAREHOUSE?	3
CONTEXTUALIZAÇÃO DOS DATA WAREHOUSES	4
“TRENDS” RELACIONADAS.....	4
COMPARAÇÃO COM OUTRAS FERRAMENTAS DE APOIO À DECISÃO.....	5
O QUE É UM DATA LAKE?	5
DATA LAKE VS DATA WAREHOUSE	5
PANORAMA ATUAL EM DATA WAREHOUSING.....	7
CASOS DE SUCESSO EM DATA WAREHOUSING	9
CASO 1: SERVIÇO AMAZON	9
OBSTÁCULOS NO CAMINHO PARA O OBJETIVO.....	9
CONCLUSÃO	10
CASO 2: SERVIÇO DE ENTREGAS DA UPS.....	11
UM KM POR 50 MILHÕES	11
QUATRO LETRAS "V"	11
CONSTELAÇÃO DE ORION.....	12
CASO 3: BRAND X	12
MARCA X PRECISA DE AJUDA	12
A “FOUNDATION STONE”	13
TODOS OS CAMINHOS LEVAM AO DATA WAREHOUSING.....	13
FATORES E APLICAÇÃO EM CONTEXTOS SIMILARES	14
CONCLUSÃO	14
CASOS DE INSUCESSO DE DATA WAREHOUSING.....	15
CASO 1: AUTO GUYS.....	15
CASO 2: GOVERNMENT RESEARCH LABORATORY	16
CASO 3: NORTH AMERICAN TAX AGENCY.....	18
CASO 4: COMPANHIA DE SSEGUROS ESLOVENA.....	19

RAZÕES PELAS QUAIS OS PROJETOS FALHAM	22
1. COMUNICAÇÃO DEFICIENTE ENTRE UNIDADES	22
2. SUBESTIMAR OS REQUISITOS	23
3. PARTINDO DIRETO PARA O CÓDIGO	23
CONCLUSÕES A RETIRAR	24
COMPARAÇÃO ENTRE CASOS DE SUCESSO E INSUCESSO	24
ANÁLISE CRÍTICA DOS FATORES	24
CONCLUSÃO FINAL.....	24
REFERÊNCIAS	26

INTRODUÇÃO

OBJETIVOS

Este relatório consiste numa abordagem teórica, que aborda um tema relacionado com Sistemas de Informação sob a perspectiva de um **Data Warehouse**. O objetivo principal desta pesquisa será analisar e comparar **Casos de Sucesso e Insucesso em Implementações de Data Warehouses**.

O QUE É UM DATA WAREHOUSE?

Um **Data Warehouse** é um tipo de sistema de gestão de dados projetado para possibilitar e apoiar atividades de inteligência de negócios (Business Intelligence), especialmente em análises. Estes são exclusivamente destinados a realizar consultas e análises e contêm grandes quantidades de dados históricos. Os dados geralmente são derivados de uma ampla variedade de fontes, como “*log files*” de aplicativos e aplicativos de transações.

As **capacidades analíticas** deste sistema permitem que as organizações obtenham ‘*insights*’ valiosos de negócios a partir dos seus dados para aprimorar a tomada de decisões. Com o tempo, este constrói um registo histórico que pode ser de elevado valor para cientistas de dados ou analistas de negócios. Tendo essas capacidades, um **Data Warehouse** pode ser considerado como a “*single source of truth*” de uma organização.

CONSTITUIÇÃO DE UM DATA WAREHOUSE?

Inclui, frequentemente, os seguintes elementos:

- Uma base de dados relacional para armazenar e gerir dados;
- Uma solução de extração, carregamento e transformação (ELT) para preparar os dados para análise;
- Capacidades de análise estatística, relatórios e “*data-mining*”;
- Ferramentas de análise de clientes para visualizar e apresentar dados aos utilizadores;
- Outras aplicações analíticas mais sofisticadas que geram informações, com aplicação de algoritmos de inteligência artificial, e/ou recursos gráficos que possibilitam diferentes tipos de análises de dados em escala.

CONTEXTUALIZAÇÃO DOS DATA WAREHOUSES

“TRENDS” RELACIONADAS

No que toca ao desenvolvimento atual dos **Data Warehouses**, a inteligência artificial já está a moldar os processos relacionados aos mesmos de várias maneiras. Ao implementar “*trends*” impulsionadas pela inteligência artificial, as empresas têm vivenciado melhorias significativas na velocidade e precisão do processamento de dados, o que tem levado a uma tomada de decisões mais eficiente.

Uma das observadas nos **Data Warehouses** é o uso de inteligência artificial para auxiliar no processo de extração, transformação e carga (ETL). **Ferramentas de ETL** apoiadas por **IA** podem automatizar tarefas repetitivas, otimizar o desempenho das mesmas e reduzir o potencial do erro humano. Com a inteligência artificial a cuidar de tarefas menos complexas, os engenheiros de dados podem concentrar-se em tarefas mais complexas (projetar modelos de dados, treinar algoritmos de “*Machine Learning*” e criar “*views*” de dados).

Por exemplo, a **Coca-Cola** utiliza ferramentas de ETL alimentadas por inteligência artificial para automatizar tarefas de integração de dados na sua cadeia de fornecimentos global, otimizando os processos de aquisição e fornecimento.

Outra “*trend*” nos **Data Warehouses** é o uso de ferramentas alimentadas por inteligência artificial para modelagem inteligente de dados. A inteligência artificial pode analisar fontes de dados e gerar automaticamente modelos de dados, considerando as relações entre “*data points*”. Isto economiza tempo e recursos que, de outra forma, precisariam horas a criar manualmente modelos de dados. Além disso, pode melhorar a precisão e a complexidade dos dados.

Por exemplo, o **Walmart** utiliza técnicas de modelagem de dados inteligentes com uso da inteligência artificial para casos de uso específicos, como gestão da cadeia de fornecimento e análise de clientes. A otimização do **Data Warehouse** permite que o **Walmart** identifique rapidamente e com precisão as tendências no comportamento do cliente, além de prever a demanda por produtos específicos para garantir uma experiência de compra tranquila para o cliente.

Com isto, a inteligência artificial está cada vez mais a ser utilizada para automatizar os processos de limpeza de dados nos **Data Warehouses**. Esta limpeza, ou preparação de dados, envolve o uso de inteligência artificial para detetar e remover imprecisões, inconsistências, erros e informações ausentes de um **Data Warehouse**, garantindo que os dados sejam precisos e

confiáveis. As organizações podem assim aproveitar os algoritmos avançados e poder computacional robusto para processar e limpar eficientemente grandes volumes de dados.

Por exemplo, a **GE Healthcare** utiliza ferramentas de limpeza de dados alimentadas por inteligência artificial para aprimorar a qualidade dos dados nos registos médicos eletrónicos, reduzindo o risco de erros no diagnóstico e tratamento dos pacientes.

COMPARAÇÃO COM OUTRAS FERRAMENTAS DE APOIO À DECISÃO

No que toca a utilizar de outras ferramentas de apoio à decisão, existe uma que é semelhante a um **Data Warehouse**. A ferramenta em questão é o chamado **Data Lake**.

O QUE É UM DATA LAKE?

Tendo em conta a definição de um **Data Warehouse**, já referida anteriormente, os **Data Lakes** preenchem uma lacuna dos **Data Warehouses**. Os **Data Lakes** armazenam grandes repositórios de dados. Ao contrário dos outros, estes são muito flexíveis e podem realizar muitas análises diferentes, que podem ser utilizadas para inteligência de negócios (Business Intelligence). Além disso, não são condicionados para se adequarem a um determinado propósito. No entanto, tal como os **Data Warehouses**, os **Data Lakes** são utilizados pelos cientistas e engenheiros de dados, e as perceções encontradas são então usadas por empresas para tomar decisões orientadas para o futuro.

DATA LAKE VS DATA WAREHOUSE

Num **Data Warehouse**, os dados são transformados e organizados à medida que são extraídos do ponto de origem e armazenados de acordo com a estrutura definida no mesmo. Num **Data Lake**, os dados são transmitidos e armazenados na forma pura, para que possam ser usados quando necessário. Por essa razão, um **Data Lake** pode conter todos os tipos de dados, tem menor custo e possui um tempo de processamento mais rápido.

Atualmente, na maior parte dos casos, um **Data Warehouse** é usado para armazenar dados e fornecer painéis e/ou visualizações de dados (gráficos, tabelas, coordenadas geográficas). No

entanto, a abordagem mais ágil é recorrer ao **Data Lake** para composição de outros dados e análises mais profundas.

Data: os **Data Lakes** possuem dados não estruturados, pois vêm diretamente da fonte sem serem filtrados. Nos **Data Warehouses**, a situação é oposta, ou seja, têm dados estruturados que já foram filtrados e organizados, prontos para serem utilizados numa base de dados relacional.

Custo: o **Data Lake** geralmente é menos dispendioso, pois não exige que os dados sejam organizados e se encaixem num esquema específico. No entanto, dependendo da capacidade de armazenamento necessária e da localização, pode ser possível encontrar ou adquirir melhores **Data Warehouses** para armazenar grandes quantidades de dados.

Flexibilidade: com a natureza estruturada dos **Data Warehouses**, a capacidade de serem “ágeis” e analisar todos os tipos de dados pode ser um desafio. Isso significa que, para empresas e organizações, estes devem ser usados para cenários pré-definidos. Os **Data Lakes** podem fazer o oposto, pois a sua composição sem estrutura permite que eles se dimensionem e ofereçam também “*insights*” quase em tempo real. No entanto, com essa composição, geralmente apenas engenheiros de dados treinados trabalham com eles.

Segurança: as empresas frequentemente armazenam dados sensíveis em bases de dados e precisam de garantir a sua segurança. Como os **Data Warehouses** existem há décadas, são mais desenvolvidos e possuem protocolos de segurança mais robustos.

Utilizadores: ao analisar os utilizadores potenciais para qualquer aplicação de armazenamento, os **Data Warehouses** e os **Data Lakes** são desenvolvidos com diferentes utilizadores em mente. Como mencionado anteriormente, com a estrutura organizada e rígida dos **Data Warehouses**, estes podem ser facilmente utilizados por empresas e respetivos funcionários. Os **Data Lakes**, com a sua estrutura flexível, eram destinados a ser operados por engenheiros de dados para extrair o máximo de proveito deles. No entanto, estão a ser desenvolvidas ferramentas para lhes fornecer interfaces interativas, fáceis de usar e sem código, que aproveitam os dados e fornecem “*insights*” procurados pelos líderes de negócios.

PANORAMA ATUAL EM DATA WAREHOUSING

Atualmente, os **Data Warehouses** funcionam como repositórios flexíveis e escaláveis para centralizar os dados de uma empresa e facilitar o acesso às informações para análises. As empresas continuam a adotar os mesmos a um ritmo acelerado.

No entanto, devem existir certas práticas no que toca à implementação de um **Data Warehouse**:

I. Envolver “stakeholders” desde o início e com frequência.

Um **Data Warehouse** deve atender às necessidades dos “stakeholders”, como gerentes de departamento, analistas de negócios e cientistas de dados, pois todos acedem a informações contidas no mesmo para realizar análises e criar relatórios. Por exemplo, a colaboração com gerentes e executivos de alto nível mantém um projeto de **Data Warehousing** alinhado com a estratégia de negócios geral da empresa. Trabalho colaborativo com quem toma as decisões ajuda a garantir que estejam comprometidos com o projeto desde o início.

II. Incorporar uma política de dados.

Se os dados alimentados num **Data Warehouse** forem de baixa qualidade, centralizá-los para análise seria inútil — os resultados das análises seriam imprecisos. Para evitar isso, as organizações devem implementar processos robustos de política de dados. Os departamentos devem trabalhar para definir as políticas de segurança, colaboração e retenção para os seus ativos de dados, com base nos seus requisitos comerciais e legais.

III. Definir funções de utilizador.

As funções de utilizador determinam quem pode ler, escrever e atualizar dados dentro de um **Data Warehouse**. Se, por exemplo, um campo precisar de ser atualizado nos dados de origem de um departamento, de quem é a responsabilidade de atualizar os trabalhos de **ETL** para contemplar isso? As atualizações de código e dados precisam de aprovação da direção? O que acontece se alguém quiser integrar uma nova fonte de dados?

Sem processos apropriados e controlo de acessos, é provável que os utilizadores comprometam os dados ao não coordenar os seus esforços, especialmente em grandes organizações, com muitos analistas a trabalhar com **Data Warehouses**. No entanto, as empresas também devem garantir que o controlo de utilizadores não seja excessivamente restritivo, já que sistemas excessivamente burocráticos podem inibir a produtividade.

As organizações devem encontrar um equilíbrio entre a segurança e a flexibilidade operacional necessárias para que os analistas trabalhem de forma eficaz.

IV. Compreender o Design do esquema de um Data Warehouse.

Uma organização deve projetar os seus esquemas para se adequarem à tecnologia do **Data Warehouse** que está a utilizar e às suas necessidades. Por exemplo, a estrutura normalizada de um esquema floco de neve, requer menos armazenamento e recursos de processamento do que a estrutura ligeiramente mais desnormalizada de um esquema estrela, mas este último facilita consultas de dados mais rápidas.

V. Iterar, Testar e Repetir.

Adotar uma abordagem ágil para o desenvolvimento e manutenção de um **Data Warehouse** pode aprimorar o desempenho do repositório e a sua capacidade de se adaptar às necessidades em constante mudança de uma organização. Ao utilizar ciclos curtos de desenvolvimento com tarefas pequenas e bem definidas, juntamente com planos de teste, as equipas de desenvolvimento podem obter “feedback” mais rápido sobre os resultados dos “stakeholders” relevantes e, em seguida, iterar para melhorar os seus sistemas e processos. Isso cria um ciclo rápido de feedback para o desenvolvimento do produto e permite que uma empresa identifique e resolva problemas relacionados com o seu **Data Warehouse** antes que afetem os utilizadores.

VI. Aproveitar o ELT e os Data Warehouses em nuvem.

Os processos de **ETL** e **ELT** são utilizados para extrair dados da sua origem, transformá-los conforme necessário e armazená-los no **Data Warehouse**. Ao mover a etapa de transformação para o final do processo, o **ELT** permite que as organizações extraiam dados e comecem a analisá-los mais rapidamente. Os **Data Warehouses** em nuvem são bem adequados para uso com **ELT**, já que seus recursos de **CPU** podem lidar com a transformação de dados após o carregamento dos mesmos. Como o **ELT** carrega dados no sistema de destino antes de serem transformados, uma empresa deve ter uma ferramenta de modelagem de dados, mesmo que seja apenas **SQL**, para preparar os dados para o uso em análises. Os engenheiros de dados que constroem e mantêm os **Data Warehouses** devem ir buscar a orientação de especialistas no assunto, de modo a fornecer aos utilizadores finais os dados num formato que atenda às suas necessidades.

CASOS DE SUCESSO EM DATA WAREHOUSING

CASO 1: SERVIÇO AMAZON

A **Amazon** é uma das maiores e mais bem-sucedidas empresas do mundo, com um negócio diversificado que inclui computação em nuvem, conteúdo digital, entre outros. Como uma empresa que gera grandes quantidades de dados, incluindo serviços de **Data Warehousing**, a **Amazon** precisa de gerir e analisar os seus dados de maneira eficaz. Um dos principais impulsionadores do negócio da **Amazon** é sua plataforma de comércio online, que permite que os clientes comprem uma ampla variedade de produtos por meio do website e de aplicações móveis. As necessidades de **Data Warehousing** da **Amazon** nesta área estão focadas em recolher, armazenar e analisar dados relacionados ao comportamento do cliente, histórico de compras, entre outras métricas. Esses dados são usados para otimizar o mecanismo de recomendações de produtos da Amazon, personalizar a experiência de compra para clientes individuais e identificar estratégias de crescimento. A outra unidade principal de negócios da **Amazon** é a **Amazon Web Services (AWS)**, que oferece serviços de computação em nuvem gerenciados para empresas e indivíduos. A AWS gera quantidades significativas de dados da sua infraestrutura de dados em nuvem, incluindo dados de uso e de desempenho do cliente. Para gerir e analisar esses dados modernos de maneira eficaz, a **Amazon** conta com tecnologias de **Data Warehousing** como o **Amazon Redshift**, que permite à AWS fornecer análises e “*insights*” em tempo real para os seus clientes.

Além desses negócios, a **Amazon** também possui necessidades significativas de **Data Warehousing** em conteúdo digital (vídeo, música e livros). O negócio de publicidade da **Amazon** depende da análise de dados para identificar conceitos-chave e direcionar anúncios de maneira mais eficaz para públicos específicos.

OBSTÁCULOS NO CAMINHO PARA O OBJETIVO

A Amazon enfrentou vários desafios. A empresa precisava de integrar dados de várias fontes num **Data Warehouse** centralizado. Isso exigiu o desenvolvimento de “*pipelines*” de dados personalizados para recolher e transformar dados num formato padrão. As necessidades de **Data Warehousing** da **Amazon** são vastas e estão em constante crescimento, exigindo uma solução escalável. A empresa adotou uma arquitetura distribuída de **Data Warehouse** usando

tecnologias como o **Amazon Redshift**, permitindo o armazenamento e a análise de dados em escala de “*petabytes*”.

Como uma empresa que gera “*Big Data*”, esta desejava garantir que a sua solução de **Data Warehousing** pudesse fornecer análises e “*insights*” em tempo real.

A Amazon armazena dados sensíveis de clientes no seu **Data Warehouse**, o que implica a priorização da segurança de dados. Para se proteger contra ameaças de segurança, a marca implementa várias medidas de segurança, incluindo criptografia, controles de acesso e deteção de ameaças.

No entanto, construir e manter uma solução de **Data Warehouse** pode ser caro. Mas a Amazon utiliza soluções de **Data Warehouse** baseadas em nuvem (**Redshift**) para minimizar custos.

CONCLUSÃO

A **Amazon** encontrou as ferramentas certas e implementou um **Data Warehouse** bem-sucedido, obtendo os seguintes principais resultados comerciais:

- **Melhoria nas decisões orientadas por dados**: capacidade de aceder e analisar dados de maneira eficiente levou a decisões mais informadas e estratégicas;
- **Melhor capacitação do cliente**: permitiu personalizar a experiência do cliente, oferecendo recomendações mais precisas e relevantes;
- **Decisões mais eficazes em termos de custo**: Ao otimizar os custos por meio de soluções baseadas em nuvem, conseguiu tomar decisões mais económicas;
- **Melhoria no desempenho**: num melhor desempenho operacional e analítico;
- **Vantagem competitiva**: consolidou sua posição no mercado e obteve vantagem competitiva;
- **Escalabilidade**: grandes volumes de dados e suporte do crescimento contínuo.

Sendo assim, a implementação do **Data Warehouse** pela **Amazon** impulsionou o crescimento e o sucesso da empresa.

CASO 2: SERVIÇO DE ENTREGAS DA UPS

A **United Parcel Service (UPS)** é uma empresa americana de entregas de encomendas fundada em 1907, com uma receita anual de 71 bilhões de dólares e serviços logísticos em mais de 175 países. Além disso, a marca distribui mercadorias, serviços de despacho aduaneiro, serviços postais e consultoria. A **UPS** processa aproximadamente 300 milhões de solicitações de rastreamento diariamente. Esse feito foi alcançado, entre outros, graças a um **Data Warehouse**.

UM KM POR 50 MILHÕES

Em 2013, a **UPS** afirmou que hospedava a maior **Database Relacional DB2** do mundo em dois **Data Centers** nos Estados Unidos para operações globais. Com o tempo, as operações globais começaram a aumentar, assim como a quantidade de dados semiestruturados. O objetivo era utilizar diferentes formas **Data Warehousing** para tomar melhores decisões comerciais.

Um dos problemas fundamentais era a otimização de rotas. Segundo uma entrevista com o **CEO** da **UPS**, economizar 1 quilómetro por dia por motorista poderia economizar 1,5 milhão de litros de combustível por ano ou 50 milhões de dólares no total. No entanto, os dados estavam distribuídos no **DB2**: alguns estavam em repositórios incluídos, alguns locais e alguns em “*spreadsheets*”. A **UPS** precisava então de resolver primeiro o problema da infraestrutura de dados e só depois otimizar a rota.

QUATRO LETRAS "V"

O ecossistema de **Big Data** lida eficientemente com os quatro "V": volume, validade, velocidade e variedade. A **UPS** experimentou com “*clusters*” **Hadoop** e integrou os detalhes de armazenamento e sistema de computação nesse ecossistema. Atualizaram o **Data Warehouse** e a capacidade de processamento para lidar com “*petabytes*” de dados, sendo essa uma das maiores realizações tecnológicas da **UPS**. Os seguintes componentes **Hadoop** foram utilizados:

- **HDFS** para armazenamento;
- **Map Reduce** para processamento rápido;
- **Streaming Kafka**;
- **Sqoop (SQL-to-Hadoop)** para ingestão;

- **Hive & Pig** para consultas estruturadas em dados não estruturados;
- Sistema de monitoramento para nós de dados e nomes;

Mas isso é apenas especulação, porque, devido à confidencialidade, a **UPS** não divulgou as ferramentas e as tecnologias que utilizaram no seu ecossistema de **Big Data**.

CONSTELAÇÃO DE ORION

O resultado foi um projeto de otimização de rotas chamado **ORION (On-Road Integrated Optimization and Navigation)**, com duração de quatro anos. Em termos de custos, cerca de 1 bilhão de dólares por ano. O **ORION** usou os resultados para **Data Warehousing** e calcular **Big Data**, obtendo análises de mais de 300 milhões de “Data Points” para otimizar milhares de rotas por minuto com base em informações em tempo real. Além dos benefícios económicos, o projeto **ORION** reduziu aproximadamente 100 milhões de quilómetros de envio e uma redução de 100 000 toneladas nas emissões de carbono.

CASO 3: BRAND X

Em geral, o tópico de casos específicos de implementação de **Data Warehouses** é frequentemente mantido em segredo. Pode haver casos de consentimento e interesses legítimos nos contratos. Existem exemplos de trabalho de código aberto, mas a grande maioria está em bibliotecas pagas. O tema é tão relevante que é possível ganhar dinheiro com isso. Portanto, às vezes, há casos "abertos", mas o nome da marca não é divulgado.

MARCA X PRECISA DE AJUDA

Líder mundial em bombas industriais, válvulas, controlos, entre outros, e precisava de ajuda para extrair dados de diversos sistemas **ERP**. Eles queriam isso a partir de 42 instâncias de **ERP**, arquivos planos padronizados e recolher todas as informações de um **Data Warehouse**. Os sistemas **ERP** eram de diferentes fornecedores (**Oracle, SAP, BAAN, Microsoft, PRMS**), complicando ainda mais a situação. O cliente também desejava um conjunto de métricas e um painel central para combinar todas as informações de diferentes locais em todo o mundo. O projeto surgiu de uma demanda crescente por dados corporativos

provenientes da gestão de base de dados. A empresa percebeu que o seu **Data Warehouse** precisava de um repositório central para todos os dados das suas localidades em todo o mundo. As solicitações frequentemente vinham de cima para baixo, e quando um administrador precisava de acesso aos dados corretos, havia problemas logísticos na extração.

A “FOUNDATION STONE”

O centro de desenvolvimento terceirizado contratado elaborou um plano, segundo o qual os dados do **ERP** foram extraídos de 8 grandes bases de dados e colocados num **Data Warehouse** corporativo. Isso envolveu a integração de 5 instâncias do **Oracle ERP** com 3 instâncias do **SAP ERP**. **Rapid Marts** também foram integrados aos sistemas **Oracle ERP** para melhorar o progresso do projeto.

Um dos principais desafios foi a necessidade de maior padronização de campos ou definições de dados operacionais nos sistemas ERP. Para resolver esse problema, o contratado desenvolveu uma ferramenta de serviço de dados que permite o acesso ao **Backend** da base de dados e que permitiu exibir as informações de maneira adequada. Desde então, o cliente sabia quais os campos a usar e como configurá-los cada vez que uma nova instância do ERP era encontrada. Esses padrões de definição de dados foram a “*foundation stone*” do projeto e mudaram completamente a forma como os dados do cliente eram tratados.

TODOS OS CAMINHOS LEVAM AO DATA WAREHOUSING

A empresa agora tem uma maneira comum e consistente de obter indicadores críticos. O efeito a longo prazo do projeto é a facilidade de obtenção de informações. O que antes era um processo demorado e inconsistente para obter informações relevantes num nível agregado agora foi otimizado para armazenar dados num repositório central com uma equipa a controlar tudo.

FATORES E APLICAÇÃO EM CONTEXTOS SIMILARES

Existem várias práticas comuns entre implementações bem-sucedidas de **Data Warehousing**, incluindo:

- Implementações bem-sucedidas de **Data Warehousing** começam com uma compreensão clara dos objetivos comerciais e de como pode apoiar esses objetivos;
- O processo de modelagem de dados é crucial;
- O **Data Warehouse** é tão bom quanto os dados que ele contém;
- Implementações bem-sucedidas de **Data Warehousing** exigem processos eficientes de integração de dados que possam operar com grandes volumes de dados e garantir consistência e precisão;
- O **Data Warehouse** precisa de ajustes contínuos de desempenho para otimizar o desempenho das consultas;
- Um fator crítico no **Data Warehousing** é uma interface amigável que torne fácil para os seus utilizadores finais, aceder aos dados e realizar consultas e análises complexas;
- A melhoria contínua é essencial para garantir que o **Data Warehouse** permaneça relevante para o negócio.

CONCLUSÃO

Implementações competentes de **Data Warehousing** combinam a experiência técnica e uma compreensão profunda dos detalhes do negócio e das necessidades do utilizador.

CASOS DE INSUCESSO DE DATA WAREHOUSING

CASO 1: AUTO GUYS

A empresa neozelandesa **Auto Guys**, iniciou um projeto de **Data Warehousing** há 4 anos, mas nunca alcançou o uso total. Após o declínio do suporte inicial ao projeto, a administração reviu os seus motivos para o **Data Warehouse** e decidiu reiniciar o projeto com algumas mudanças. Uma razão para a reestruturação, de acordo com o gerente de projeto, foi a complexidade do modelo inicialmente utilizado pela **Auto Guys**.

Inicialmente, o gerente do projeto do **Data Warehouse** queria usar um modelo dimensional para informações tabulares. No entanto, pressões políticas forçaram o uso precoce do sistema. Consequentemente, os dados do “*mainframe*” foram em grande parte replicados e essas tabelas não funcionaram bem com as ferramentas de ambiente de consulta que foram adquiridas. O número de tabelas e junções, e o subsequente crescimento do catálogo, impediram a **Auto Guys** de usar os dados como pretendido num formato empresarial conciso e coerente. O gerente de projeto também indicou que quanto maior o Data Warehouse, maior a necessidade de apoio de alto nível da administração - algo que a **Auto Guys** não tinha na sua primeira tentativa de configurar o **Data Warehouse**. Outro problema mencionado pelo gerente de projeto foi que a tecnologia escolhida pela **Auto Guys** para o projeto era relativamente nova na época, então não foi aceite e não conquistou a confiança que um projeto usando tecnologia comprovada teria recebido. Isso é um risco inerente a qualquer adoção de tecnologia "de ponta". O abandono inicial do projeto foi sem dúvida acelerado tanto pelo desconforto corporativo com essa nova tecnologia quanto pela falta de apoio da administração.

Pouco tempo depois de abandonar o projeto, a administração sentiu pressão para reestabelecê-lo. Como a **Auto Guys** planejava inicialmente um **Data Warehouse** abrangente em toda a empresa, eles tinham uma capacidade de computação considerável. Isso foi utilizado num projeto muito menor que se concentrou exclusivamente numa única área temática. Outras áreas temáticas deveriam ser adicionadas assim que o projeto inicial da área temática fosse concluído. A **Auto Guys** espera expandir o armazém para 2 “terabytes” dentro de 1 ano ou 2 e eventualmente ampliar para o projetado Data Warehouse abrangente em toda a empresa. A maior diferença entre pré e pós-resgate será que o projeto evoluirá incrementalmente.

Dada a sua experiência com o **Data Warehouse**, o gerente de projeto fez as seguintes observações resumidas:

- a gestão das expectativas é crucial para qualquer projeto de armazém de dados de grande porte;
- a tecnologia comprovada, embora não essencial, torna o projeto mais fácil de explicar e justificar;
- a construção de um **Data Warehouse** de grande porte deve ser tratada mais como um esforço de **P&D** do que como um projeto típico de **TI**, devido ao tempo necessário para concluir o projeto, à quantidade de dinheiro envolvida e ao foco de curto prazo da administração.

CASO 2: GOVERNMENT RESEARCH LABORATORY

O **Laboratório de Pesquisa Governamental (GRL)** dos Estados Unidos da América, possui um departamento financeiro em cada um dos 15 laboratórios quase idênticos que se reportam à sua sede nacional. Um dos membros da equipa financeira, “**Bob Stewart**” estava familiarizado com os relatórios financeiros mensais exigidos pela sede. Embora os relatórios financeiros em si não fossem complicados, o acesso ao “*mainframe*” onde os dados eram armazenados era necessário, e era preciso entender **COBOL** para gerar qualquer relatório que diferisse do padrão. Uma vez por mês, os relatórios eram distribuídos em formato papel, e cada membro da equipa financeira examinava e arquivava os mesmos. Se os relatórios exigissem alguma alteração, alguém da área de **TI**, ou uma das duas pessoas do departamento financeiro familiarizadas com **COBOL**, era contactado. Devido a essas dificuldades de relatório, um gerente de **TI** fez a sugestão de que o primeiro **Data Warehouse** da empresa fosse construído, e que o departamento financeiro fosse o principal beneficiário. Duas pessoas da **TI** e um analista financeiro começaram a trabalhar em tempo integral no projeto. O gerente de **TI** então ofereceu um bônus aos técnicos de **TI** se conseguissem colocar o **Data Warehouse** em funcionamento até o final do ano fiscal, que estava a apenas 4 meses de distância. Tanto os membros da **TI** quanto os membros da equipa financeira, firmemente cravados na realidade, sabiam que isso seria uma tarefa difícil, se não mesmo impossível. Mas resolveram dar o seu melhor e tentaram uma transferência completa de todos os relatórios disponíveis para o **Data Warehouse**. Quando ficou claro que isso era muito ambicioso, eles eliminaram todos os relatórios detalhados e focaram-se apenas nos resumos, assumindo que o material mais detalhado poderia ser integrado em algum momento após o prazo inicial.

A equipa teve sucesso e transferiu todos os relatórios de resumo para o **Data Warehouse** no final do ano fiscal. No entanto, o facto de as tabelas necessárias estarem ativas e funcionais não era um indicador de sucesso futuro.

O primeiro problema envolveu alterações na base de dados do “mainframe” que foram iniciadas ao mesmo tempo, mas sem coordenação com o projeto de **Data Warehousing**. Ao mesmo tempo em que a base para o **Data Warehouse** estava a ser estabelecida, o sistema de planeamento no “mainframe” estava a passar por modificações não capturadas no Data Warehouse. Em particular, as mudanças nos padrões de contabilidade de custos dentro da organização alteraram o número de categorias principais de resumo de cinco padrão usadas no passado para 7, tornando as tradicionais 5 praticamente inúteis.

O segundo problema ocorreu quando o objetivo de estabelecer o **Data Warehouse** se tornou o objetivo final. Como o analista financeiro da **GRL** descreve, o período de feedback e modificação que ele esperava após setembro nunca aconteceu. A solução preliminar tornou-se a solução permanente. O analista posteriormente soube que a **TI** sempre teve a intenção de configurar o sistema, mas só financiou a sua manutenção básica. Modificações não estavam no orçamento, e o departamento financeiro, marginalmente incluído no projeto de **Data Warehousing**, nunca teve um orçamento que financiaria a inclusão de mais dados e alterações no sistema. Essencialmente, a **GRL** viu-se com um **Data Warehouse** que continha poucos dados e dados desatualizados devido a alterações de formato nos padrões de contabilidade de custos da **GRL**. Além disso, nem o departamento financeiro nem a **TI** orçamentaram as alterações necessárias para criar um **Data Warehouse** totalmente funcional. Esses dois problemas por si só teriam encerrado a maioria das iniciativas de **Data Warehousing**, mas os problemas não terminaram aí.

O **Data Warehouse** deveria resolver dois problemas de acessibilidade. Um envolvia a necessidade de “expertise” em linguagem COBOL sempre que um relatório precisava de ser alterado, e o outro envolvia a pura quantidade de documentos impressos dispersados e arquivados.

Em vez de fornecer uma solução, os relatórios teoricamente disponíveis numa rede eram tratados de maneira semelhante aos relatórios antigos. Por um lado, o software de acesso aos dados instalado no **PC** de cada utilizador, era frequentemente incompatível com a mistura de software já existente. Muitos utilizadores finais, portanto, acharam difícil aceder ao **Data Warehouse**, e aqueles que conseguiam aceder ao **Data Warehouse** tiveram más experiências com o novo sistema que simplesmente não o usaram. Além disso, a pequena minoria que não teve problemas de acessibilidade simplesmente imprimiu cópias impressas dos relatórios, o que não representou uma grande mudança em relação ao que era feito no passado. As barreiras de

programação existentes quando o conhecimento de **COBOL** era necessário simplesmente mudaram de forma. O **PowerBuilder**, uma ferramenta muito voltada para programadores, foi selecionado para construir as interfaces do utilizador. Ironicamente, a **TI** tinha apenas 1 indivíduo com habilidades em **PowerBuilder**, criando assim mais uma dificuldade que existia com o **COBOL**. A situação permaneceu a mesma, se não pior, por 3 anos após a primeira iniciativa de **Data Warehousing**.

Após 3 anos, finalmente, outro gerente de projeto de **TI** interessou-se pela ideia de dar vida ao antigo **Data Warehouse**. Este foi motivado pela solução da organização para o problema do **Y2K**, que envolvia abandonar o antigo sistema “mainframe” e transferir os relatórios antigos para o **Data Warehouse**. Felizmente, o interesse foi acompanhado por um financiamento que permitiu que as melhorias previstas desde o início do primeiro projeto finalmente se concretizassem. Além disso, todos os usuários conseguiram aceder a relatórios baseados na Web.

Várias coisas deveriam ter sido feitas de maneira diferente na **GRL**:

- A iniciativa de **Data Warehousing** deveria ter estado em sintonia com as mudanças no “mainframe” e outras iniciativas de **TI** em todo o laboratório;
- Planeamento e recursos deveriam ter sido projetados para o futuro;
- Um projeto-piloto deveria ter sido realizado, o que provavelmente teria identificado uma série de problemas técnicos e de ajuste fino;
- Os prazos deveriam ter sido razoáveis. Ainda assim, dados os desenvolvimentos mais recentes, o analista financeiro da **GRL** classifica a sua experiência como uma decepção parcial. “*Poderia ter sido muito melhor*”, ele explica. “*Poderia ter sido feito certo... pelos motivos certos.*”.

CASO 3: NORTH AMERICAN TAX AGENCY

A administração do **Departamento de Conformidade de uma Agência Tributária** na América do Norte identificou os benefícios potenciais de um **Data Warehouse**. Eles desejavam utilizá-lo para aumentar a conformidade voluntária, e o grupo de **TI** desta agência estava interessado em ajudar a unidade a construir o mesmo. Uma proposta formal foi elaborada, identificando as aplicações específicas para o **Data Warehouse**, os benefícios a serem obtidos por meio dessas aplicações e o custo total envolvido. A equipa do projeto seguiu os passos adequados para documentar os benefícios do projeto, especialmente os possíveis a entregar a

curto prazo. Foi um projeto ambicioso a levar três a cinco anos para ser construído, com um custo de 25 a 30 milhões de dólares.

A equipa do projeto acreditava que tinha o forte apoio do patrocinador executivo. No entanto, após a aprovação da proposta, o interesse do parceiro da unidade de negócios começou a diminuir. Uma razão oferecida foi que o patrocinador executivo não entendia completamente o tempo necessário para concluir o projeto, o montante de financiamento necessário ou os benefícios intermediários que seriam realizados (ou seja, em cada estágio de desenvolvimento, o valor estava a ser adicionado ao **Departamento de Conformidade**). Outra razão para a perda de interesse pode ter sido que o Departamento de Conformidade foi solicitado a liderar sob uma perspetiva corporativa (ou seja, tomar decisões sobre a arquitetura de dados e problemas de dados). O **Departamento de Conformidade** resistiu em aceitar esse papel e expressou uma preocupação de que talvez isso fosse, na verdade, um papel do grupo de **TI**. Como resultado, eles relutaram em fornecer recursos adicionais à equipa do projeto. O grupo de **TI** desenvolveu a carta de intenções e realizou todas as tarefas que podiam em relação à identificação dos requisitos comerciais, mas chegou a um ponto em que precisavam da contribuição de especialistas em negócios, que deveriam ser fornecidos pelo **Departamento de Conformidade**. Foram feitas tentativas repetidas pelo grupo de **TI** para atrair participantes especializados em negócios. Por fim, o grupo de **TI** comunicou formalmente ao **Departamento de Conformidade** que não poderia continuar sem o apoio deles.

Embora as razões para a perda de patrocínio não sejam claras, é provável que o custo total e a longa duração do projeto tenham contribuído para o enfraquecimento do interesse. O interesse no **Data Warehouse** nesta organização específica não está completamente morto. No entanto, um novo patrocinador de uma unidade de negócios diferente dentro da **Agência Tributária** surgiu. Esse novo parceiro de negócios também percebeu que o **Data Warehouse** poderia ajudá-los a lidar com a falta de controlo dentro do programa. Planos foram feitos para prosseguir com um Data Warehouse em menor escala.

CASO 4: COMPANHIA DE SSEGUROS ESLOVENA

A administração de uma **Companhia de Seguros Eslovena (CPE)** decidiu que o negócio precisava de um **Data Warehouse**.

Inicialmente, a administração estava preocupada em alcançar dois objetivos principais:

- minimizar a fraude em pedidos de seguros;

- investigar o lucro dos serviços de seguro prestados.

O patrocinador do projeto do **Data Warehouse** era um vice-presidente sénior que tinha visto algumas demonstrações de ferramentas de “*Data Mining*” e sentia que ter essa capacidade beneficiaria muito a **CPE**. O administrador de sistemas/base de dados da empresa também apoiou o projeto porque os programadores estavam a produzir um número crescente de relatórios individualizados, aumentando a carga nos sistemas OLTP. Ele acreditava que, por meio do uso de um **Data Warehouse**, o sistema seria capaz de produzir todos os relatórios necessários. Para alcançar esses objetivos, a **CPE** contratou uma equipa de uma empresa de desenvolvimento de software e integração de sistemas para construir o **Data Warehouse**.

Desde o início do projeto, tanto a administração quanto o departamento de **TI** forneceram pouca orientação. O vice-presidente sénior acreditava que o trabalho deveria ser realizado pelo departamento de TI, atribuiu a responsabilidade do projeto ao departamento de TI e não queria participar. A empresa não exigiu que a equipa de **Data Warehousing** preparasse um caso de negócios. Eles não identificaram quem seriam os utilizadores específicos do Data Warehouse nem forneceram um limite de custo. A falta de comprometimento da **CPE** com o projeto foi ainda mais evidenciada pela sua falta de interesse e participação no processo. Esses fatores levaram a uma diminuição do entusiasmo pelo projeto.

Inicialmente, a administração da empresa estava mais interessada na capacidade de analisar detalhadamente os pedidos de seguro de veículos. No entanto, surgiram logo dois problemas principais:

- quando a equipa começou a construir **Data Warehouse**, a empresa estava a mudar sua plataforma de computação. Como resultado, a equipa de **Data Warehousing** não podia trabalhar com dados de pedidos de seguro. A equipa decidiu continuar usando os dados disponíveis;
- a equipa de **Data Warehousing** descobriu que a análise de pedidos de seguro não seria possível, uma vez que os sistemas OLTP da empresa não registavam os dados necessários para tais análises. Posteriormente, o modelo de dados do **Data Warehouse** teve de ser ajustado.

Embora a administração tenha imaginado um grande **Data Warehouse** desde o início, eles logo perceberam que não poderiam incorporar todos os dados num único grande modelo de dados. A administração decidiu que certas limitações deveriam ser feitas e que seria necessário construir um Data Warehouse menor.

Mesmo após a criação do **Data Warehouse**, a equipa ainda não tinha certeza de quem o iria usar. A equipa começou a trabalhar com dois utilizadores em potencial após a primeira

versão ter sido implementada. Foram feitas alterações no modelo de dados e nos procedimentos de carga para atender às necessidades desses dois grupos de utilizadores. Levou mais de um ano para a equipa de **Data Warehousing** construir o **Data Warehouse**, embora os membros da equipa sentissem que o projeto deveria ter levado apenas metade do tempo. Uma razão para o atraso foi que o departamento de TI estava com menos empregados e sobrecarregado.

Como resultado das restrições de tempo, a equipa de **TI não estava disposta ou não conseguia participar.** A equipa de **Data Warehousing** também enfrentou dificuldades de programação e recebeu informações conflituosas do departamento de **TI**, o que aumentou o tempo necessário para concluir o projeto. A visão da empresa para o projeto era usar uma ferramenta de “*Data Mining*” para detetar fraudes em pedidos de seguros. No entanto, no final, essa visão nunca foi totalmente realizada. A principal razão para essa decepção foi a falta de um caso de negócios. A partir desse fator, outros problemas surgiram.

Primeiro, como não havia um caso de negócios, não estava claro quem beneficiaria do Data Warehouse e quem continuaria a apoiá-lo.

Em segundo lugar, a empresa não tinha uma compreensão clara do que seria necessário para concluir o projeto e quais seriam os benefícios esperados. Curiosamente, foi apenas após o início do projeto que a equipa de **Data Warehousing** percebeu qual era a posição da empresa. Ou seja, a empresa confiava na equipa de **Data Warehousing** para concluir o projeto e acreditava que a equipa, como implementadora, concluiria o projeto sem a participação dela. A cultura corporativa da empresa é aquela em que os utilizadores são desencorajados a fazer pedidos ao departamento de TI sob a suposição de que a TI sabe o que é melhor para os utilizadores. Como resultado, os utilizadores em potencial não puderam participar no projeto de Data Warehouse, apesar dos pedidos repetidos da equipa. No final, a equipa recebeu poucas contribuições tanto do departamento de **TI** quanto dos utilizadores que estavam a tentar ajudar. Finalmente, o facto de haver falta de dados detalhados disponíveis nos sistemas OLTP e de a base de dados e as aplicações de pedidos estarem indisponíveis, levou a problemas que poderiam ter sido evitados, se houvesse um caso de negócios preparado.

As lições a serem aprendidas com este caso são expressas de melhor maneira pela gerente da equipa de **Data Warehousing**, que trabalhou neste projeto. Quando perguntada sobre o que faria de diferente, a gerente da equipa afirma o seguinte: “*Definitivamente, não começaria o projeto até que um caso de negócios para Data Warehouse fosse claramente definido, os potenciais usuários fossem conhecidos e dispostos a participar; e eu tivesse um compromisso do departamento de TI deles para participar.*”.

RAZÕES PELAS QUAIS OS PROJETOS FALHAM

Como podemos ver pelas experiências anteriores, há casos em que os projetos de **Data Warehousing** falham. Algumas das razões do mesmo acontecer podem ser:

1. COMUNICAÇÃO DEFICIENTE ENTRE UNIDADES

Uma comunicação eficaz não é apenas uma componente chave para o sucesso na vida, mas é uma componente principal para o sucesso em qualquer projeto de **Data Warehousing**. Uma razão importante pela qual projetos de **Data Warehousing** falham é a comunicação deficiente entre as partes interessadas do projeto e a equipa técnica/TI que está a desenvolver e a codificar.

O trabalho da equipa técnica é ouvir os requisitos comerciais das diferentes unidades de negócios envolvidas e transformar esses requisitos em requisitos técnicos. O único modo do processo funcionar é se a equipa técnica tiver uma compreensão profunda do negócio e de terminologia relacionada, além de entender que “*insights*” a empresa deseja obter.

A equipa técnica deve garantir que obtém respostas claras para perguntas altamente importantes:

- Quais “*insights*” estamos a tentar obter com o novo **Data Warehouse**?
- Que informações estamos à procura para ajudar o nosso negócio a crescer e obter uma vantagem competitiva?
- Quais os resultados esperados?

Uma comunicação eficaz durante o planeamento do projeto quase sempre inclui pensamento e planeamento organizados, divulgação completa de detalhes importantes, terminologia adequada, empatia e honestidade.

Também já existiram situações em que a equipa técnica não compreende completamente o que as unidades de negócios desejam, e em vez de garantir que entendam fazendo boas perguntas e obtendo boas respostas, muitas vezes a equipa técnica começa a construir o **Data Warehouse**.

Portanto, a grande lição, é não encarar as reuniões iniciais de design entre unidades de negócios e TI de maneira leve. Uma comunicação excelente é crucial durante essas reuniões de forma a criar um **Data Warehouse** excepcional.

2. SUBESTIMAR OS REQUISITOS

Subestimar os requisitos de um projeto é outra causa principal do fracasso de um projeto de **Data Warehousing**. Um problema comum em projetos de **DW** que estão com dificuldades é que as partes interessadas do projeto acreditam que um projeto custará menos do que realmente custa. Isso muitas vezes é verdade, quer “custo” se refira a dinheiro, tempo ou recursos. Prazos agressivos podem ser cruciais para o sucesso do projeto e certamente têm o seu lugar no mundo dos negócios e em projetos de **TI** como o **Data Warehousing**, mas esses prazos precisam de ser sempre razoáveis e acordados antecipadamente por todas as partes interessadas.

Além disso, o orçamento para o projeto também deve ser razoável. Economizar na construção de um **Data Warehouse** raramente é uma boa ideia, e é provável que um “barato” custe mais a longo prazo. Para evitar subestimar os requisitos do projeto, a equipa técnica precisa de fazer um excelente trabalho de comunicação sobre quanto tempo o projeto levará e quais os recursos necessários. É crucial que a equipa técnica também gerencie adequadamente as expectativas de todos e garanta que todas as partes interessadas estejam na mesma página.

3. PARTINDO DIRETO PARA O CÓDIGO

A última razão principal pela qual alguns projetos de **Data Warehouse** falham é bastante significativa, especialmente para pessoas de tecnologia, pois pode ser fácil sucumbir a empolgação de criar um **Data Warehouse** sem ter todos os recursos e planos de projeto necessários no lugar.

A paixão é ótima, mas o resultado frequentemente não é. O design do projeto deve ser totalmente concluído e revisto antes que tempo e dinheiro sejam gastos na codificação. Entrar apressadamente na codificação nunca deve ser feito. Quanto mais detalhes e explicações sobre o que é desejado, mais claros são os objetivos e melhor será o desenvolvimento do projeto.

CONCLUSÕES A RETIRAR

COMPARAÇÃO ENTRE CASOS DE SUCESSO E INSUCESSO

Ao analisar os casos de sucesso e insucesso em implementações de **Data Warehouse**, várias disparidades e semelhanças surgem. Nos casos de sucesso como, por exemplo, o da **Amazon**, foi evidente que uma compreensão clara dos objetivos de negócios, uma modelagem de dados eficiente e a integração eficaz de dados foram fundamentais. A abordagem da **Amazon** para a segurança de dados, escalabilidade e uso de soluções baseadas em nuvem também destacou a importância da escolha de tecnologias apropriadas.

Por outro lado, em relação aos casos de insucesso, como o da **Auto Guys**, revelaram falhas na comunicação entre unidades de negócios e equipas técnicas, subestimação dos requisitos do projeto e falta de comprometimento organizacional. A ausência de um caso de negócios claro e da participação adequada de usuários e departamentos de **TI** contribuiu significativamente para o insucesso.

ANÁLISE CRÍTICA DOS FATORES

A comunicação eficiente entre unidades de negócios e equipas técnicas emergiu como um fator crítico. Nos casos bem-sucedidos, a compreensão clara das necessidades empresariais e a tradução adequada dessas necessidades em requisitos técnicos foram vitais. Por outro lado, nos casos de insucesso, a falta de alinhamento entre as expectativas das partes interessadas e a execução técnica prejudicou os projetos. Outro fator crítico foi a adequada estimativa dos requisitos do projeto. Nos projetos bem-sucedidos, houve uma compreensão realista do tempo, recursos e custos envolvidos. No entanto, casos de insucesso indicaram subestimação desses fatores, levando a atrasos, orçamentos estourados e, em última análise, ao fracasso do projeto.

CONCLUSÃO FINAL

Com base nas análises, as conclusões para um **Data Warehouse** bem-sucedido incluem:

- **Compreensão Clara dos Objetivos de Negócios:** iniciar com uma compreensão aprofundada dos objetivos de negócios;
- **Comunicação Eficiente:** comunicação aberta e eficiente entre unidades de negócios e equipes técnicas;
- **Estimativa Realista de Requisitos:** estimativa realista dos requisitos do projeto, incluindo tempo, recursos e custos;
- **Envolvimento Ativo dos Interessados:** envolvimento contínuo de todas as partes interessadas, desde a concepção até a implementação;
- **Escolha de Tecnologias Adequadas:** A escolha de tecnologias apropriadas, considerando segurança, escalabilidade e eficiência.

Evitar armadilhas requer uma abordagem proativa para mitigar riscos, garantir uma execução eficiente e manter uma comunicação constante entre todas as partes envolvidas no projeto de **Data Warehouse**.

REFERÊNCIAS

- I. [What Is a Data Warehouse | Oracle Portugal](#)
- II. [AI-powered Data Warehousing: Emerging Trends and Predictions \(astera.com\)](#)
- III. [Data Lake vs Data Warehouse: How to Choose the Right One - \(peoplespheres.com\)](#)
- IV. [6 Critical Data Warehousing Best Practices \(Strategy\) | Stitch \(stitchdata.com\)](#)
- V. [Successful Data Warehousing in Real Life \(dataforest.ai\)](#)
- VI. [Data Warehousing Failures: Case Studies and Findings \(moreheadstate.edu\)](#)
- VII. [Why Data Warehouse Projects Fail | Key2 Consulting](#)
- VIII. [<https://chat.openai.com/>](#)